Diskrete Wahrscheinlichkeitstheorie
Repetitorium

Jonas Hübotter

Outline

Zählen

Wahrscheinlichkeit

Bedingte Wahrscheinlichkeit

Diskrete Zufallsvariablen

Kontinuierliche Zufallsvariablen

Induktive Statistik

Markovketten

Plan I

Zählen
- Ergebnismengen und Ereignisse
- Abzählen von Mengen

Ergebnismengen und Ereignisse

Definition 1

Eine Ergebnismenge ist die Menge aller möglichen Elementarereignisse eines Experiments.

Ergebnismengen und Ereignisse

Definition 1

Eine Ergebnismenge ist die Menge aller möglichen Elementarereignisse eines Experiments.

Definition 2

Ein Ereignis ist eine Teilmenge der Ergebnismenge.

Ergebnismengen und Ereignisse

Definition 1

Eine Ergebnismenge ist die Menge aller möglichen Elementarereignisse eines Experiments.

Definition 2

Ein Ereignis ist eine Teilmenge der Ergebnismenge.

Naive Definition der Wahrscheinlichkeit eines Ereignisses A in der Ergebnismenge S:

Ergebnismengen und Ereignisse

Definition 1

Eine Ergebnismenge ist die Menge aller möglichen Elementarereignisse eines Experiments.

Definition 2

Ein Ereignis ist eine Teilmenge der Ergebnismenge.

Naive Definition der Wahrscheinlichkeit eines Ereignisses A in der Ergebnismenge S:

$$P(A) = \frac{\#\text{ günstige Ergebnisse}}{\#\text{ mögliche Ergebnisse}} = \frac{|A|}{|S|}$$

Ergebnismengen und Ereignisse

Definition 1

Eine Ergebnismenge ist die Menge aller möglichen Elementarereignisse eines Experiments.

Definition 2

Ein Ereignis ist eine Teilmenge der Ergebnismenge.

Naive Definition der Wahrscheinlichkeit eines Ereignisses A in der Ergebnismenge S:

$$P(A) = \frac{\#\text{ günstige Ergebnisse}}{\#\text{ mögliche Ergebnisse}} = \frac{|A|}{|S|}$$

Annahmen:

Ergebnismengen und Ereignisse

Definition 1

Eine Ergebnismenge ist die Menge aller möglichen Elementarereignisse eines Experiments.

Definition 2

Ein Ereignis ist eine Teilmenge der Ergebnismenge.

Naive Definition der Wahrscheinlichkeit eines Ereignisses A in der Ergebnismenge S:

$$P(A) = \frac{\#\text{ günstige Ergebnisse}}{\#\text{ mögliche Ergebnisse}} = \frac{|A|}{|S|}$$

Annahmen:

- alle Ergebnisse gleich wahrscheinlich

Ergebnismengen und Ereignisse

Definition 1

Eine Ergebnismenge ist die Menge aller möglichen Elementarereignisse eines Experiments.

Definition 2

Ein Ereignis ist eine Teilmenge der Ergebnismenge.

Naive Definition der Wahrscheinlichkeit eines Ereignisses A in der Ergebnismenge S:

$$P(A) = \frac{\#\text{ günstige Ergebnisse}}{\#\text{ mögliche Ergebnisse}} = \frac{|A|}{|S|}$$

Annahmen:

- alle Ergebnisse gleich wahrscheinlich
- endlicher Ergebnisraum

Abzählen von Mengen

Multiplikationsregel

Betrachte $i \in [m]$ Experimente mit n_i möglichen Ergebnissen. Dann ist die Gesamtanzahl an möglichen Ergebnissen

$$\prod_{i=1}^{m} n_i.$$

Kombinatorik-Tabelle

Gegeben n Objekte, wähle k Objekte.

	Reihenfolge	$\neg$ Reihenfolge
Zurücklegen		
$\neg$ Zurücklegen		

Kombinatorik-Tabelle

Gegeben n Objekte, wähle k Objekte.

	Reihenfolge	$\neg$ Reihenfolge
Zurücklegen	n^k	
$\neg$ Zurücklegen		

Kombinatorik-Tabelle

Gegeben n Objekte, wähle k Objekte.

	Reihenfolge	$\neg$ Reihenfolge
Zurücklegen	n^k	
$\neg$ Zurücklegen		$\binom{n}{k}$

Kombinatorik-Tabelle

Gegeben n Objekte, wähle k Objekte.

	Reihenfolge	$\neg$ Reihenfolge
Zurücklegen	n^k	
$\neg$ Zurücklegen	$\frac{n!}{(n-k)!}$	$\binom{n}{k}$

Kombinatorik-Tabelle

Gegeben n Objekte, wähle k Objekte.

	Reihenfolge	$\neg$ Reihenfolge
Zurücklegen	n^k	$\binom{n+k-1}{k}$
$\neg$ Zurücklegen	$\frac{n!}{(n-k)!}$	$\binom{n}{k}$

Plan I

Wahrscheinlichkeit
- σ-Algebren
- Wahrscheinlichkeitsräume
- Multivariate- und Randwahrscheinlichkeiten

σ-Algebren

Definition 3

Gegeben die Ergebnismenge S. Die Menge $\mathcal{A} \subseteq \mathcal{P}(S)$ ist eine σ-Algebra über S wenn die folgenden Eigenschaften erfüllt sind:

σ-Algebren

Definition 3

Gegeben die Ergebnismenge S. Die Menge $\mathcal{A} \subseteq \mathcal{P}(S)$ ist eine σ-Algebra über S wenn die folgenden Eigenschaften erfüllt sind:

- $S \in \mathcal{A}$

σ-Algebren

Definition 3

Gegeben die Ergebnismenge S. Die Menge $\mathcal{A} \subseteq \mathcal{P}(S)$ ist eine σ-Algebra über S wenn die folgenden Eigenschaften erfüllt sind:

- $S \in \mathcal{A}$;
- falls $A \in \mathcal{A}$, dann $\bar{A} \in \mathcal{A}$

σ-Algebren

Definition 3

Gegeben die Ergebnismenge S. Die Menge $\mathcal{A} \subseteq \mathcal{P}(S)$ ist eine σ-Algebra über S wenn die folgenden Eigenschaften erfüllt sind:

- $S \in \mathcal{A}$;
- falls $A \in \mathcal{A}$, dann $\bar{A} \in \mathcal{A}$; und
- $\forall n \in \mathbb{N}.\ A_n \in \mathcal{A} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$.

σ-Algebren

Definition 3

Gegeben die Ergebnismenge S. Die Menge $\mathcal{A} \subseteq \mathcal{P}(S)$ ist eine σ-Algebra über S wenn die folgenden Eigenschaften erfüllt sind:

- $S \in \mathcal{A}$;
- falls $A \in \mathcal{A}$, dann $\bar{A} \in \mathcal{A}$; und
- $\forall n \in \mathbb{N}.\ A_n \in \mathcal{A} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$.

Warum benötigen wir σ-Algebren?

σ-Algebren

Definition 3

Gegeben die Ergebnismenge S. Die Menge $\mathcal{A} \subseteq \mathcal{P}(S)$ ist eine σ-Algebra über S wenn die folgenden Eigenschaften erfüllt sind:

- $S \in \mathcal{A}$;
- falls $A \in \mathcal{A}$, dann $\bar{A} \in \mathcal{A}$; und
- $\forall n \in \mathbb{N}.\ A_n \in \mathcal{A} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$.

Warum benötigen wir σ-Algebren?

Um Ereignisse im Kontext eines Wahrscheinlichkeitsraumes beschreiben zu können.

Wahrscheinlichkeitsräume

Definition 4

Gegeben die Ergebnismenge S und die σ-Algebra $\mathcal{A}$ über S.

Wahrscheinlichkeitsräume

Definition 4

Gegeben die Ergebnismenge S und die σ-Algebra $\mathcal{A}$ über S. Die Funktion

$$P : \mathcal{A} \to [0, 1]$$

ist ein Wahrscheinlichkeitsmaß auf $\mathcal{A}$ falls die Kolmogorov Axiome erfüllt sind:

Wahrscheinlichkeitsräume

Definition 4

Gegeben die Ergebnismenge S und die σ-Algebra $\mathcal{A}$ über S. Die Funktion

$$P : \mathcal{A} \to [0, 1]$$

ist ein Wahrscheinlichkeitsmaß auf $\mathcal{A}$ falls die Kolmogorov Axiome erfüllt sind:

- $P(S) = 1$;

Wahrscheinlichkeitsräume

Definition 4

Gegeben die Ergebnismenge S und die σ-Algebra $\mathcal{A}$ über S. Die Funktion

$$P : \mathcal{A} \to [0, 1]$$

ist ein Wahrscheinlichkeitsmaß auf $\mathcal{A}$ falls die Kolmogorov Axiome erfüllt sind:

- $P(S) = 1$;
- $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$ falls $\forall i \neq j.\ A_i \cap A_j = \emptyset$.

Definition 5

Für ein Ereignis $A \in \mathcal{A}$, $P(A)$ ist die Wahrscheinlichkeit von A.

Definition 5

Für ein Ereignis $A \in \mathcal{A}$, $P(A)$ ist die Wahrscheinlichkeit von A.

Definition 6

Ein Wahrscheinlichkeitsraum besteht aus

- einer Ergebnismenge S;
- einer σ-Algebra $\mathcal{A}$ über S; und
- einem Wahrscheinlichkeitsmaß P auf $\mathcal{A}$.

Für einen Wahrscheinlichkeitsraum gelten die folgenden Eigenschaften:

Für einen Wahrscheinlichkeitsraum gelten die folgenden Eigenschaften:

- $P(\emptyset) = 0$

Für einen Wahrscheinlichkeitsraum gelten die folgenden Eigenschaften:

- $P(\emptyset) = 0$
- $P(S) = 1$

Für einen Wahrscheinlichkeitsraum gelten die folgenden Eigenschaften:

- $P(\emptyset) = 0$
- $P(S) = 1$
- $0 \leq P(A) \leq 1$ für alle $A \in \mathcal{A}$

Für einen Wahrscheinlichkeitsraum gelten die folgenden Eigenschaften:

- $P(\emptyset) = 0$
- $P(S) = 1$
- $0 \leq P(A) \leq 1$ für alle $A \in \mathcal{A}$
- $P(\bar{A}) = 1 - P(A)$ für alle $A \in \mathcal{A}$

Für einen Wahrscheinlichkeitsraum gelten die folgenden Eigenschaften:

- $P(\emptyset) = 0$
- $P(S) = 1$
- $0 \leq P(A) \leq 1$ für alle $A \in \mathcal{A}$
- $P(\bar{A}) = 1 - P(A)$ für alle $A \in \mathcal{A}$
- falls $A, B \in \mathcal{A}$ und $A \subseteq B$, dann $P(A) \leq P(B)$

Weiterhin gilt die Siebformel:

$$P(\bigcup_{i=1}^{n} A_i) = \sum_{I \subseteq [n], I \neq \emptyset} (-1)^{|I|+1} \cdot P(\bigcap_{i \in I} A_i).$$

Weiterhin gilt die Siebformel:

$$P(\bigcup_{i=1}^{n} A_i) = \sum_{I \subseteq [n], I \neq \emptyset} (-1)^{|I|+1} \cdot P(\bigcap_{i \in I} A_i).$$

Und die Bool'sche Ungleichung:

$$P(\bigcup_{i=1}^{n} A_i) \leq \sum_{i=1}^{n} P(A_i).$$

Multivariate- und Randwahrscheinlichkeiten

Eine Randwahrscheinlichkeit ist die Wahrscheinlichkeit eines einzelnen Ereignisses unabhängig von anderen Ereignissen.

Multivariate- und Randwahrscheinlichkeiten

Eine Randwahrscheinlichkeit ist die Wahrscheinlichkeit eines einzelnen Ereignisses unabhängig von anderen Ereignissen.

Eine multivariate Wahrscheinlichkeit ist die Wahrscheinlichkeit von zwei oder mehreren Ereignissen gleichzeitig aufzutreten:

$$P(A, B) = P(A \cap B).$$

Plan I

Bedingte Wahrscheinlichkeit
- A-priori und a-posteriori
- Unabhängigkeit
- Konditionierung

A-priori und a-posteriori

Bedingte Wahrscheinlichkeit *aktualisiert* die Wahrscheinlichkeit eines Ereignisses A gegeben eine neue Information B.

A-priori und a-posteriori

Bedingte Wahrscheinlichkeit *aktualisiert* die Wahrscheinlichkeit eines Ereignisses A gegeben eine neue Information B.

$P(A)$ heißt a-priori und $P(A|B)$ a-posteriori Wahrscheinlichkeit.

A-priori und a-posteriori

Bedingte Wahrscheinlichkeit *aktualisiert* die Wahrscheinlichkeit eines Ereignisses A gegeben eine neue Information B.

$P(A)$ heißt a-priori und $P(A|B)$ a-posteriori Wahrscheinlichkeit.

$$P(A|B) = \frac{P(A, B)}{P(B)}.$$

Die a-posteriori Wahrschenilichkeit ist die multivariate Wahrscheinlichkeit des Ereignisses A und der Information B relativ zu der Wahrscheinlichkeit der Information B.

Unabhängigkeit

Zwei Ereignisse sind unabhängig wenn das Auftreten des einen Ereignisses nicht die Wahrscheinlichkeit des anderen Ereignisses beeinflusst.

Unabhängigkeit

Zwei Ereignisse sind unabhängig wenn das Auftreten des einen Ereignisses nicht die Wahrscheinlichkeit des anderen Ereignisses beeinflusst.

Zwei Ereignisse A und B sind unabhängig
$\iff P(A|B) = P(A)$ for $P(B) > 0$

Unabhängigkeit

Zwei Ereignisse sind unabhängig wenn das Auftreten des einen Ereignisses nicht die Wahrscheinlichkeit des anderen Ereignisses beeinflusst.

Zwei Ereignisse A und B sind unabhängig
$\iff P(A|B) = P(A)$ for $P(B) > 0$
$\iff P(B|A) = P(B)$ for $P(A) > 0$

Unabhängigkeit

Zwei Ereignisse sind unabhängig wenn das Auftreten des einen Ereignisses nicht die Wahrscheinlichkeit des anderen Ereignisses beeinflusst.

Zwei Ereignisse A und B sind unabhängig
$\iff P(A|B) = P(A)$ for $P(B) > 0$
$\iff P(B|A) = P(B)$ for $P(A) > 0$
$\iff P(A, B) = P(A)P(B)$.

Konditionierung

Einige Eigenschaften folgen direkt aus der Definition der bedingten Wahrscheinlichkeit:

Konditionierung

Einige Eigenschaften folgen direkt aus der Definition der bedingten Wahrscheinlichkeit:

- $P(A, B) = P(B)P(A|B)$

Konditionierung

Einige Eigenschaften folgen direkt aus der Definition der bedingten Wahrscheinlichkeit:

- $P(A, B) = P(B)P(A|B) = P(A)P(B|A)$,
  da $A \cap B = B \cap A$

Konditionierung

Einige Eigenschaften folgen direkt aus der Definition der bedingten Wahrscheinlichkeit:

- $P(A, B) = P(B)P(A|B) = P(A)P(B|A)$,
  da $A \cap B = B \cap A$
- $P(A_1, \ldots, A_n) =$
  $P(A_1)P(A_2|A_1)P(A_3|A_1, A_2) \cdots P(A_n|A_1, \ldots, A_{n-1})$
  (Multiplikationssatz)

Konditionierung

Einige Eigenschaften folgen direkt aus der Definition der bedingten Wahrscheinlichkeit:

- $P(A, B) = P(B)P(A|B) = P(A)P(B|A)$,
  da $A \cap B = B \cap A$
- $P(A_1, \ldots, A_n) =$
  $P(A_1)P(A_2|A_1)P(A_3|A_1, A_2) \cdots P(A_n|A_1, \ldots, A_{n-1})$
  (Multiplikationssatz)
- $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ (Satz von Bayes)

Konditionierung

Einige Eigenschaften folgen direkt aus der Definition der bedingten Wahrscheinlichkeit:

- $P(A, B) = P(B)P(A|B) = P(A)P(B|A)$,
  da $A \cap B = B \cap A$
- $P(A_1, \ldots, A_n) =$
  $P(A_1)P(A_2|A_1)P(A_3|A_1, A_2) \cdots P(A_n|A_1, \ldots, A_{n-1})$
  (Multiplikationssatz)
- $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ (Satz von Bayes)
- $P(A) = P(A, B) + P(A, \bar{B}) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$
  (Gesetz der totalen Wahrscheinlichkeit)

Plan I

Diskrete Zufallsvariablen
- Verteilungsfunktion
- Diskrete Dichtefunktion
- Unabhängigkeit
- Bernoulli Verteilung
- Erwartungswert
- Indikatorvariablen
- Binomialverteilung
- Varianz
- Geometrische Verteilung
- Poisson Verteilung
- Wahrscheinlichkeitserzeugende Funktionen
- Momenterzeugende Funktionen
- Multivariate Dichten
- Bedingte Dichten

Plan II

Faltungen
Weitere Verteilungen
Ungleichungen

Diskrete Zufallsvariablen

Definition 7

Eine Zufallsvariable X ist eine Funktion

$$X : S \to \mathbb{R}.$$

Diskrete Zufallsvariablen

Definition 7

Eine Zufallsvariable X ist eine Funktion

$$X : S \to \mathbb{R}.$$

Eine Zufallsvariable heißt diskret wenn ihr Urbild S endlich oder abzählbar unendlich ist.

Diskrete Zufallsvariablen

Definition 7

Eine Zufallsvariable X ist eine Funktion

$$X : S \to \mathbb{R}.$$

Eine Zufallsvariable heißt diskret wenn ihr Urbild S endlich oder abzählbar unendlich ist.

Der Wertebereich einer diskreten Zufallsvariable

$$X(S) = \{x \in \mathbb{R}.\ \exists A \in S.\ X(A) = x\}$$

ist ebenfalls abzählbar.

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Definition 8

Die Verteilungsfunktion einer Zufallsvariable X ist definiert als $F_X(x) = P(X \leq x) \in [0, 1]$.

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Definition 8

Die Verteilungsfunktion einer Zufallsvariable X ist definiert als $F_X(x) = P(X \leq x) \in [0, 1]$.

Eigenschaften von Verteilungsfunktionen:

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Definition 8

Die Verteilungsfunktion einer Zufallsvariable X ist definiert als $F_X(x) = P(X \leq x) \in [0, 1]$.

Eigenschaften von Verteilungsfunktionen:

- monoton wachsend

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Definition 8

Die Verteilungsfunktion einer Zufallsvariable X ist definiert als $F_X(x) = P(X \leq x) \in [0, 1]$.

Eigenschaften von Verteilungsfunktionen:

- monoton wachsend
- rechtsseitig stetig

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Definition 8

Die Verteilungsfunktion einer Zufallsvariable X ist definiert als $F_X(x) = P(X \leq x) \in [0, 1]$.

Eigenschaften von Verteilungsfunktionen:

- monoton wachsend
- rechtsseitig stetig
- $F_X(x) \xrightarrow{x \to -\infty} 0$

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Definition 8

Die Verteilungsfunktion einer Zufallsvariable X ist definiert als $F_X(x) = P(X \leq x) \in [0, 1]$.

Eigenschaften von Verteilungsfunktionen:

- monoton wachsend
- rechtsseitig stetig
- $F_X(x) \xrightarrow{x \to -\infty} 0$
- $F_X(x) \xrightarrow{x \to \infty} 1$

Verteilungsfunktion

$X \leq x$ ist ein Ereignis.

Definition 8

Die Verteilungsfunktion einer Zufallsvariable X ist definiert als $F_X(x) = P(X \leq x) \in [0, 1]$.

Eigenschaften von Verteilungsfunktionen:

- monoton wachsend
- rechtsseitig stetig
- $F_X(x) \xrightarrow{x \to -\infty} 0$
- $F_X(x) \xrightarrow{x \to \infty} 1$

Daher, $P(a < X \leq b) = F_X(b) - F_X(a)$.

Diskrete Dichtefunktion

Definition 9

Die diskrete Dichtefunktion einer diskreten Zufallsvariable X ist definiert als $f_X(x) = P(X = x) \in [0, 1]$ wobei

$$\sum_{x \in X(S)} f_X(x) = 1.$$

Die Verteilungsfunktion von X kann von der Dichtefunktion von X erhalten werden indem über die Dichtefunktion summiert wird

$$F_X(x) = \sum_{x' \leq x} f_X(x').$$

Die Verteilungsfunktion von X kann von der Dichtefunktion von X erhalten werden indem über die Dichtefunktion summiert wird

$$F_X(x) = \sum_{x' \leq x} f_X(x').$$

Die Dichtefunktion von X kann von der Verteilungsfunktion von X erhalten werden indem die *Sprünge* in der Verteilungsfunktion identifiziert werden

$$f_X(x) = F_X(x) - F_X(prev(x)).$$

Unabhängigkeit

Zwei Zufallsvariablen sind unabhängig wenn das Wissen des Wertes einer Zufallsvariable keine Auswirkungen auf die Verteilung der anderen Zufallsvariable hat.

Unabhängigkeit

Zwei Zufallsvariablen sind unabhängig wenn das Wissen des Wertes einer Zufallsvariable keine Auswirkungen auf die Verteilung der anderen Zufallsvariable hat.

Zwei diskrete Zufallsvariablen X und Y sind unabhängig
$\iff$ die Ereignisse $X = x$ und $Y = y$ sind unabhängig

Unabhängigkeit

Zwei Zufallsvariablen sind unabhängig wenn das Wissen des Wertes einer Zufallsvariable keine Auswirkungen auf die Verteilung der anderen Zufallsvariable hat.

Zwei diskrete Zufallsvariablen X und Y sind unabhängig
$\iff$ die Ereignisse $X = x$ und $Y = y$ sind unabhängig
$\iff$ die Ereignisse $X \leq x$ und $Y \leq y$ sind unabhängig.

Bernoulli Verteilung

Definition 10 ($X \sim Bern(p)$)

Eine diskrete Zufallsvariable X ist Bernoulli-verteilt mit Parameter p falls $X(S) = \{0, 1\}$ und $P(X = 1) = p$.

Bernoulli Verteilung

Definition 10 ($X \sim Bern(p)$)

Eine diskrete Zufallsvariable X ist Bernoulli-verteilt mit Parameter p falls $X(S) = \{0, 1\}$ und $P(X = 1) = p$.

Übersicht

- $E(X) = p$
- $Var(X) = p(1 - p)$
- $G_X(s) = 1 - p + ps$
- $M_X(s) = 1 - p + pe^s$

Erwartungswert

Definition 11

Der Erwartungswert $E(X)$ einer Zufallsvariable X ist das arithmetische Mittel einer großen Anzahl an Realisierungen von X.

Erwartungswert

Definition 11

Der Erwartungswert $E(X)$ einer Zufallsvariable X ist das arithmetische Mittel einer großen Anzahl an Realisierungen von X.

$$E(X) = \sum_{x \in X(S)} x \cdot P(X = x)$$

Erwartungswert

Definition 11

Der Erwartungswert $E(X)$ einer Zufallsvariable X ist das arithmetische Mittel einer großen Anzahl an Realisierungen von X.

$$\begin{aligned} E(X) &= \sum_{x \in X(S)} x \cdot P(X = x) \\ &= \sum_{A \in S} X(A) \cdot P(A). \end{aligned}$$

Erwartungswert

Definition 11

Der Erwartungswert $E(X)$ einer Zufallsvariable X ist das arithmetische Mittel einer großen Anzahl an Realisierungen von X.

$$\begin{aligned} E(X) &= \sum_{x \in X(S)} x \cdot P(X = x) \\ &= \sum_{A \in S} X(A) \cdot P(A). \end{aligned}$$

Für unendlich große Wahrscheinlichkeitsräume ist absolute Konvergenz von $E(X)$ eine notwendige Bedingung für die Existenz von $E(X)$.

Eigenschaften des Erwartungswerts:

Eigenschaften des Erwartungswerts:

- falls $\forall A \in S.\ X(A) \leq Y(A)$, dann $E(X) \leq E(Y)$ (Monotonie)

Eigenschaften des Erwartungswerts:

- falls $\forall A \in S.\ X(A) \leq Y(A)$, dann $E(X) \leq E(Y)$ (Monotonie)
- $E(a \cdot X + b) = a \cdot E(X) + b$, $E(X + Y) = E(X) + E(Y)$ (Linearität)

Eigenschaften des Erwartungswerts:

- falls $\forall A \in S.\ X(A) \leq Y(A)$, dann $E(X) \leq E(Y)$ (Monotonie)
- $E(a \cdot X + b) = a \cdot E(X) + b$, $E(X + Y) = E(X) + E(Y)$ (Linearität)
- $E(\prod_{i=1}^{n} X_i) = \prod_{i=1}^{n} E(X_i)$ falls $X_1, \ldots, X_n$ unabhängig (Multiplikativität).

Definition 12

$E(X^i)$ heißt *i*-tes Moment der Zufallsvariable X und $E((X - E(X))^i)$ heißt *i*-tes zetrales Moment von X.

Das sogenannte law of the unconscious statistician (LOTUS) kann verwendet werden, um den Erwartungswert von transformierten Zufallsvariablen zu finden.

$$E(g(X)) = \sum_{x \in X(S)} g(x) \cdot P(X = x).$$

Indikatorvariablen

Definition 13

Gegeben ein Ereignis A, die Zufallsvariable $I_A \sim Bern(P(A))$ ist die Indikatorvariable des Ereignisses A.

Indikatorvariablen

Definition 13

Gegeben ein Ereignis A, die Zufallsvariable $I_A \sim Bern(P(A))$ ist die Indikatorvariable des Ereignisses A.

Eigenschaften von Indikatorvariablen:

Indikatorvariablen

Definition 13

Gegeben ein Ereignis A, die Zufallsvariable $I_A \sim Bern(P(A))$ ist die Indikatorvariable des Ereignisses A.

Eigenschaften von Indikatorvariablen:

- $E(I_A) = P(A)$

Indikatorvariablen

Definition 13

Gegeben ein Ereignis A, die Zufallsvariable $I_A \sim Bern(P(A))$ ist die Indikatorvariable des Ereignisses A.

Eigenschaften von Indikatorvariablen:

- $E(I_A) = P(A)$
- $E(I_{A_1} \cdots I_{A_n}) = P(A_1 \cap \cdots \cap A_n)$.

Binomialverteilung

Definition 14 ($X \sim Bin(n, p)$)

Eine diskrete Zufallsvariable X ist binomial-verteilt mit Parametern n und p falls X die #Erfolge in n unabhängigen $Bern(p)$ Versuchen modelliert.

Binomialverteilung

Definition 14 ($X \sim Bin(n, p)$)

Eine diskrete Zufallsvariable X ist binomial-verteilt mit Parametern n und p falls X die #Erfolge in n unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Binomialverteilung

Definition 14 ($X \sim Bin(n, p)$)

Eine diskrete Zufallsvariable X ist binomial-verteilt mit Parametern n und p falls X die #Erfolge in n unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Übersicht

- $E(X) = np$

Binomialverteilung

Definition 14 ($X \sim Bin(n, p)$)

Eine diskrete Zufallsvariable X ist binomial-verteilt mit Parametern n und p falls X die #Erfolge in n unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Übersicht

- $E(X) = np$
- $Var(X) = np(1-p)$
- $G_X(s) = (1-p+ps)^n$
- $M_X(s) = (1-p+pe^s)^n$

Varianz

Definition 15

Die Varianz $Var(X)$ einer Zufallsvariable X ist ein Maß der absoluten Abweichung einer Zufallsvariablen von ihrem Erwartungswert.

$$Var(X) = E((X - E(X))^2)$$

Varianz

Definition 15

Die Varianz $Var(X)$ einer Zufallsvariable X ist ein Maß der absoluten Abweichung einer Zufallsvariablen von ihrem Erwartungswert.

$$\begin{aligned} Var(X) &= E((X - E(X))^2) \\ &= E(X^2) - E(X)^2. \end{aligned}$$

Varianz

Definition 15

Die Varianz $Var(X)$ einer Zufallsvariable X ist ein Maß der absoluten Abweichung einer Zufallsvariablen von ihrem Erwartungswert.

$$\begin{aligned} Var(X) &= E((X - E(X))^2) \\ &= E(X^2) - E(X)^2. \end{aligned}$$

$SD(X) = \sqrt{Var(X)}$ heißt Standardabweichung von X.

Varianz

Definition 15

Die Varianz $Var(X)$ einer Zufallsvariable X ist ein Maß der absoluten Abweichung einer Zufallsvariablen von ihrem Erwartungswert.

$$\begin{aligned} Var(X) &= E((X - E(X))^2) \\ &= E(X^2) - E(X)^2. \end{aligned}$$

$SD(X) = \sqrt{Var(X)}$ heißt Standardabweichung von X.

Eigenschaften der Varianz:

Varianz

Definition 15

Die Varianz $Var(X)$ einer Zufallsvariable X ist ein Maß der absoluten Abweichung einer Zufallsvariablen von ihrem Erwartungswert.

$$\begin{aligned} Var(X) &= E((X - E(X))^2) \\ &= E(X^2) - E(X)^2. \end{aligned}$$

$SD(X) = \sqrt{Var(X)}$ heißt Standardabweichung von X.

Eigenschaften der Varianz:

- $Var(a \cdot X + b) = a^2 \cdot Var(X)$

Varianz

Definition 15

Die Varianz $Var(X)$ einer Zufallsvariable X ist ein Maß der absoluten Abweichung einer Zufallsvariablen von ihrem Erwartungswert.

$$\begin{aligned} Var(X) &= E((X - E(X))^2) \\ &= E(X^2) - E(X)^2. \end{aligned}$$

$SD(X) = \sqrt{Var(X)}$ heißt Standardabweichung von X.

Eigenschaften der Varianz:

- $Var(a \cdot X + b) = a^2 \cdot Var(X)$
- $Var(\sum_{i=1}^{n} X_i) = \sum_{i=1}^{n} Var(X_i)$ falls $X_1, \ldots, X_n$ unabhängig.

Geometrische Verteilung

Definition 16 ($X \sim Geom(p)$)

Eine diskrete Zufallsvariable X ist geometrisch verteilt mit Parameter p falls X die #Versuche, die zu einem Erfolg führen, in unabhängigen $Bern(p)$ Versuchen modelliert.

Geometrische Verteilung

Definition 16 ($X \sim Geom(p)$)

Eine diskrete Zufallsvariable X ist geometrisch verteilt mit Parameter p falls X die #Versuche, die zu einem Erfolg führen, in unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = p(1-p)^{k-1}, k \in \mathbb{N}.$$

Geometrische Verteilung

Definition 16 ($X \sim Geom(p)$)

Eine diskrete Zufallsvariable X ist geometrisch verteilt mit Parameter p falls X die #Versuche, die zu einem Erfolg führen, in unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = p(1-p)^{k-1}, k \in \mathbb{N}. \qquad F_X(k) = 1 - (1-p)^{\lfloor k \rfloor}.$$

Geometrische Verteilung

Definition 16 ($X \sim Geom(p)$)

Eine diskrete Zufallsvariable X ist geometrisch verteilt mit Parameter p falls X die #Versuche, die zu einem Erfolg führen, in unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = p(1-p)^{k-1}, k \in \mathbb{N}. \qquad F_X(k) = 1 - (1-p)^{\lfloor k \rfloor}.$$

Übersicht

- $E(X) = \frac{1}{p}$

Geometrische Verteilung

Definition 16 ($X \sim Geom(p)$)

Eine diskrete Zufallsvariable X ist geometrisch verteilt mit Parameter p falls X die #Versuche, die zu einem Erfolg führen, in unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = p(1-p)^{k-1}, k \in \mathbb{N}. \qquad F_X(k) = 1 - (1-p)^{\lfloor k \rfloor}.$$

Übersicht

- $E(X) = \frac{1}{p}$
- $Var(X) = \frac{1-p}{p^2}$

Geometrische Verteilung

Definition 16 ($X \sim Geom(p)$)

Eine diskrete Zufallsvariable X ist geometrisch verteilt mit Parameter p falls X die #Versuche, die zu einem Erfolg führen, in unabhängigen $Bern(p)$ Versuchen modelliert.

$$f_X(k) = p(1-p)^{k-1}, k \in \mathbb{N}. \qquad F_X(k) = 1 - (1-p)^{\lfloor k \rfloor}.$$

Übersicht

- $E(X) = \frac{1}{p}$
- $Var(X) = \frac{1-p}{p^2}$
- $G_X(s) = \frac{ps}{1-(1-p)s}$

Gedächtnislosigkeit

Durchführen von x Versuchen, von denen keiner zum Erfolg führt, verändert nicht die Wahrscheinlichkeit dafür, dass die nächsten y Versuche einen Erfolg beinhalten.

Gedächtnislosigkeit

Durchführen von x Versuchen, von denen keiner zum Erfolg führt, verändert nicht die Wahrscheinlichkeit dafür, dass die nächsten y Versuche einen Erfolg beinhalten.

Diese Eigenschaft kann wie folgt formalisiert werden:

$$P(X > y + x | X > x) = P(X > y).$$

Gedächtnislosigkeit

Durchführen von x Versuchen, von denen keiner zum Erfolg führt, verändert nicht die Wahrscheinlichkeit dafür, dass die nächsten y Versuche einen Erfolg beinhalten.

Diese Eigenschaft kann wie folgt formalisiert werden:

$$P(X > y + x | X > x) = P(X > y).$$

Die geometrische Verteilung ist die einzige gedächtnislose diskrete Verteilung.

Poisson Verteilung

Definition 17 ($X \sim Po(\lambda)$)

Eine diskrete Zufallsvariable X ist Poisson-verteilt mit Parameter λ falls X die #Ereignisse in einem festen Interval mit Rate λ modelliert, wobei die Ereignisse unabhängig von der Zeit seit dem letzten Ereignis auftreten.

Poisson Verteilung

Definition 17 ($X \sim Po(\lambda)$)

Eine diskrete Zufallsvariable X ist Poisson-verteilt mit Parameter λ falls X die #Ereignisse in einem festen Interval mit Rate λ modelliert, wobei die Ereignisse unabhängig von der Zeit seit dem letzten Ereignis auftreten.

$$f_X(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}, k \in \mathbb{N}_0.$$

Poisson Verteilung

Definition 17 ($X \sim Po(\lambda)$)

Eine diskrete Zufallsvariable X ist Poisson-verteilt mit Parameter λ falls X die #Ereignisse in einem festen Interval mit Rate λ modelliert, wobei die Ereignisse unabhängig von der Zeit seit dem letzten Ereignis auftreten.

$$f_X(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}, k \in \mathbb{N}_0. \qquad F_X(k) = e^{-\lambda} \cdot \sum_{i=0}^{\lfloor k \rfloor} \frac{\lambda^i}{i!}.$$

Poisson Verteilung

Definition 17 ($X \sim Po(\lambda)$)

Eine diskrete Zufallsvariable X ist Poisson-verteilt mit Parameter λ falls X die #Ereignisse in einem festen Interval mit Rate λ modelliert, wobei die Ereignisse unabhängig von der Zeit seit dem letzten Ereignis auftreten.

$$f_X(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}, k \in \mathbb{N}_0. \qquad F_X(k) = e^{-\lambda} \cdot \sum_{i=0}^{\lfloor k \rfloor} \frac{\lambda^i}{i!}.$$

Übersicht

- $E(X) = \lambda$

Poisson Verteilung

Definition 17 ($X \sim Po(\lambda)$)

Eine diskrete Zufallsvariable X ist Poisson-verteilt mit Parameter λ falls X die #Ereignisse in einem festen Interval mit Rate λ modelliert, wobei die Ereignisse unabhängig von der Zeit seit dem letzten Ereignis auftreten.

$$f_X(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}, k \in \mathbb{N}_0. \qquad F_X(k) = e^{-\lambda} \cdot \sum_{i=0}^{\lfloor k \rfloor} \frac{\lambda^i}{i!}.$$

Übersicht

- $E(X) = \lambda$
- $Var(X) = \lambda$

Poisson Verteilung

Definition 17 ($X \sim Po(\lambda)$)

Eine diskrete Zufallsvariable X ist Poisson-verteilt mit Parameter λ falls X die #Ereignisse in einem festen Interval mit Rate λ modelliert, wobei die Ereignisse unabhängig von der Zeit seit dem letzten Ereignis auftreten.

$$f_X(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}, k \in \mathbb{N}_0. \qquad F_X(k) = e^{-\lambda} \cdot \sum_{i=0}^{\lfloor k \rfloor} \frac{\lambda^i}{i!}.$$

Übersicht

- $E(X) = \lambda$
- $Var(X) = \lambda$
- $G_X(s) = exp(\lambda(s-1))$
- $M_X(s) = exp(\lambda(e^s - 1))$

Poisson-Approximation der Binomialverteilung

Sei $X \sim Bin(n, \lambda/n)$.

Poisson-Approximation der Binomialverteilung

Sei $X \sim Bin(n, \lambda/n)$.
Dann konvergiert die Verteilung von X zu $Po(\lambda)$ mit $n \to \infty$

Poisson-Approximation der Binomialverteilung

Sei $X \sim Bin(n, \lambda/n)$.
Dann konvergiert die Verteilung von X zu $Po(\lambda)$ mit $n \to \infty$ (d.h. für kleine λ/n).

Wahrscheinlichkeitserzeugende Funktionen

Definition 18

Gegeben eine diskrete Zufallsvariable X mit $X(S) \subseteq \mathbb{N}_0$ ist die wahrscheinlichkeitserzeugende Funktion definiert als

$$G_X(s) = \sum_{x \in X(S)} s^x \cdot P(X = x)$$

Wahrscheinlichkeitserzeugende Funktionen

Definition 18

Gegeben eine diskrete Zufallsvariable X mit $X(S) \subseteq \mathbb{N}_0$ ist die wahrscheinlichkeitserzeugende Funktion definiert als

$$\begin{aligned} G_X(s) &= \sum_{x \in X(S)} s^x \cdot P(X = x) \\ &= E(s^X). \end{aligned}$$

Wahrscheinlichkeitserzeugende Funktionen

Definition 18

Gegeben eine diskrete Zufallsvariable X mit $X(S) \subseteq \mathbb{N}_0$ ist die wahrscheinlichkeitserzeugende Funktion definiert als

$$\begin{aligned} G_X(s) &= \sum_{x \in X(S)} s^x \cdot P(X = x) \\ &= E(s^X). \end{aligned}$$

Die wahrscheinlichkeitserzeugende Funktion einer Zufallsvariable X erzeugt die Dichtefunktion von X:

$$P(X = i) = \frac{G_X^{(i)}(0)}{i!}.$$

Eigenschaften von wahrscheinlichkeitserzeugenden Funktionen:

Eigenschaften von wahrscheinlichkeitserzeugenden Funktionen:

- $E(X) = G'_X(1)$

Eigenschaften von wahrscheinlichkeitserzeugenden Funktionen:

- $E(X) = G'_X(1)$
- $Var(X) = G''_X(1) + G'_X(1) - (G'_X(1))^2$

Eigenschaften von wahrscheinlichkeitserzeugenden Funktionen:

- $E(X) = G'_X(1)$
- $Var(X) = G''_X(1) + G'_X(1) - (G'_X(1))^2$
- $G_{X+t}(s) = s^t \cdot G_X(s), t \in \mathbb{N}_0$

Eigenschaften von wahrscheinlichkeitserzeugenden Funktionen:

- $E(X) = G'_X(1)$
- $Var(X) = G''_X(1) + G'_X(1) - (G'_X(1))^2$
- $G_{X+t}(s) = s^t \cdot G_X(s), t \in \mathbb{N}_0$
- $G_{X+Y}(s) = G_X(s) \cdot G_Y(s)$ falls X, Y unabhängig

Eigenschaften von wahrscheinlichkeitserzeugenden Funktionen:

- $E(X) = G'_X(1)$
- $Var(X) = G''_X(1) + G'_X(1) - (G'_X(1))^2$
- $G_{X+t}(s) = s^t \cdot G_X(s), t \in \mathbb{N}_0$
- $G_{X+Y}(s) = G_X(s) \cdot G_Y(s)$ falls X, Y unabhängig
- $G_Z(s) = G_N(G_X(s))$ für $Z = X_1 + \cdots + X_N$, X_i unabhängig und identisch verteilt mit wahrscheinlichkeitserzeugender Funktion G_X und N unabhängig.

Momenterzeugende Funktionen

Definition 19

Gegeben eine Zufallsvariable X ist die momenterzeugende Funktion definiert als

$$M_X(s) = \sum_{x \in X(S)} e^{sx} \cdot P(X = x)$$

Momenterzeugende Funktionen

Definition 19

Gegeben eine Zufallsvariable X ist die momenterzeugende Funktion definiert als

$$\begin{aligned} M_X(s) &= \sum_{x \in X(S)} e^{sx} \cdot P(X = x) \\ &= E(e^{sX}) \end{aligned}$$

Momenterzeugende Funktionen

Definition 19

Gegeben eine Zufallsvariable X ist die momenterzeugende Funktion definiert als

$$\begin{aligned} M_X(s) &= \sum_{x \in X(S)} e^{sx} \cdot P(X = x) \\ &= E(e^{sX}) \\ &= \sum_{i=0}^{\infty} \frac{E(X^i)}{i!} \cdot s^i. \end{aligned}$$

Momenterzeugende Funktionen

Definition 19

Gegeben eine Zufallsvariable X ist die momenterzeugende Funktion definiert als

$$\begin{aligned} M_X(s) &= \sum_{x \in X(S)} e^{sx} \cdot P(X = x) \\ &= E(e^{sX}) \\ &= \sum_{i=0}^{\infty} \frac{E(X^i)}{i!} \cdot s^i. \end{aligned}$$

Die momenterzeugende Funktion einer Zufallsvariable X erzeugt das i-te Moment von X:

$$E(X^i) = M_X^{(i)}(0).$$

Eigenschaften von momenterzeugenden Funktionen:

Eigenschaften von momenterzeugenden Funktionen:

- $M_X(s) = G_X(e^s)$ if $X(S) \subseteq \mathbb{N}_0$

Eigenschaften von momenterzeugenden Funktionen:

- $M_X(s) = G_X(e^s)$ if $X(S) \subseteq \mathbb{N}_0$
- $M_{X+Y}(s) = M_X(s) \cdot M_Y(s)$ falls X, Y unabhängig.

Multivariate Dichten

Definition 20

Eine multivariate Dichte ist die Dichte von zwei oder mehr Zufallsvariablen.

$$f_{X,Y}(x, y) = P(X = x, Y = y).$$

Multivariate Dichten

Definition 20

Eine multivariate Dichte ist die Dichte von zwei oder mehr Zufallsvariablen.

$$f_{X,Y}(x, y) = P(X = x, Y = y).$$

Die Randdichte einer Zufallsvariablen kann aus einer multivariaten Dichte gewonnen werden indem über alle anderen Zufallsvariablen summiert wird:

$$f_X(x) = \sum_{y \in Y(S)} f_{X,Y}(x, y).$$

Bedingte Dichten

Definition 21

Gegeben eine multivariate Dichte von zwei Zufallsvariablen X und Y ist die bedingte Dichte von X gegeben Y die Dichte von X wenn der konkrete Wert von Y bekannt ist.

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{f_{Y|X}(y|x) \cdot f_X(x)}{f_Y(y)}.$$

Bedingte Dichten

Definition 21

Gegeben eine multivariate Dichte von zwei Zufallsvariablen X und Y ist die bedingte Dichte von X gegeben Y die Dichte von X wenn der konkrete Wert von Y bekannt ist.

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{f_{Y|X}(y|x) \cdot f_X(x)}{f_Y(y)}.$$

Der bedingte Erwartungswert der Zufallsvariablen $X|Y = y$ ist der Erwartungswert der Dichte $f_{X|Y=y}$:

$$E(X|Y = y) = \sum_{x \in X(S)} x \cdot f_{X|Y}(x|y).$$

Faltungen

Definition 22

Seien die Zufallsvariablen X und Y unabhängig und $Z = X + Y$. Dann gilt

$$f_Z(z) = \sum_{x \in X(S)} f_X(x) \cdot f_Y(z - x).$$

Faltungen

Definition 22

Seien die Zufallsvariablen X und Y unabhängig und $Z = X + Y$. Dann gilt

$$f_Z(z) = \sum_{x \in X(S)} f_X(x) \cdot f_Y(z - x).$$

Die Herleitung der Verteilung einer Summe von Zufallsvariablen gegeben deren Randverteilungen bezeichnet man auch als Faltung oder Konvolution.

Weitere Verteilungen

Definition 23 ($X \sim HypGeom(r, a, b)$)

Eine diskrete Zufallsvariable X ist hypergeometrisch verteilt mit Parametern r, a und b falls X die # von gezogenen Objekten, die eine spezifische Eigenschaft haben, in r Ziehungen ohne Zurücklegen aus $a + b$ Objekten modelliert webei b Objekte die Eigenschaft aufweisen.

Weitere Verteilungen

Definition 23 ($X \sim HypGeom(r, a, b)$)

Eine diskrete Zufallsvariable X ist hypergeometrisch verteilt mit Parametern r, a und b falls X die # von gezogenen Objekten, die eine spezifische Eigenschaft haben, in r Ziehungen ohne Zurücklegen aus $a + b$ Objekten modelliert webei b Objekte die Eigenschaft aufweisen.

$$f_X(x) = \frac{\binom{b}{x}\binom{a}{r-x}}{\binom{a+b}{r}}.$$

Weitere Verteilungen

Definition 23 ($X \sim HypGeom(r, a, b)$)

Eine diskrete Zufallsvariable X ist hypergeometrisch verteilt mit Parametern r, a und b falls X die # von gezogenen Objekten, die eine spezifische Eigenschaft haben, in r Ziehungen ohne Zurücklegen aus $a + b$ Objekten modelliert webei b Objekte die Eigenschaft aufweisen.

$$f_X(x) = \frac{\binom{b}{x}\binom{a}{r-x}}{\binom{a+b}{r}}.$$

Übersicht

- $E(X) = r \cdot \frac{b}{a+b}$

Definition 24 ($Z \sim NegBin(n, p)$)

Eine diskrete Zufallsvariable Z ist negativ binomialverteilt mit Parametern n und p falls Z die # von unabhängigen $Bern(p)$ Versuchen bevor dem n-ten Erfolg modelliert.

Definition 24 ($Z \sim NegBin(n, p)$)

Eine diskrete Zufallsvariable Z ist negativ binomialverteilt mit Parametern n und p falls Z die # von unabhängigen $Bern(p)$ Versuchen bevor dem n-ten Erfolg modelliert.

$$f_Z(z) = \binom{z-1}{n-1} p^n (1-p)^{z-n}.$$

Definition 24 ($Z \sim NegBin(n, p)$)

Eine diskrete Zufallsvariable Z ist negativ binomialverteilt mit Parametern n und p falls Z die # von unabhängigen $Bern(p)$ Versuchen bevor dem n-ten Erfolg modelliert.

$$f_Z(z) = \binom{z-1}{n-1} p^n (1-p)^{z-n}.$$

Example 25

Seien $X_1, \ldots, X_n \sim Geom(p)$ unabhängig und gleichverteilt. Dann gilt $Z = X_1 + \cdots + X_n \sim NegBin(n, p)$.

Ungleichungen

Ungleichungen vs Approximationen

Approximationen erlauben uns komplexere Probleme zu modellieren, doch ist oft nicht klar wie genau die Approximation ist.

Ungleichungen

Ungleichungen vs Approximationen

Approximationen erlauben uns komplexere Probleme zu modellieren, doch ist oft nicht klar wie genau die Approximation ist. *Ungleichungen* erlauben uns definitive Aussagen (Schranken) bezüglich der Wahrscheinlichkeit von Ereignissen zu treffen.

Definition 26 (Markov)

Gegeben eine Zufallsvariable $X \geq 0$ und $t > 0$

$$P(X \geq t) \leq \frac{E(X)}{t}.$$

Definition 26 (Markov)

Gegeben eine Zufallsvariable $X \geq 0$ und $t > 0$

$$P(X \geq t) \leq \frac{E(X)}{t}.$$

Definition 27 (Chebyshev)

Gegeben eine Zufallsvariable X und $t > 0$

$$P(|X - E(X)| \geq t) \leq \frac{Var(X)}{t^2}.$$

Definition 28 (Chernoff)

Seien $X_1, \ldots, X_n$ unabhängige, Bernoulli-verteilte Zufallsvariablen mit $X_i \sim Bern(p_i)$. Dann gelten die folgenden Ungleichungen für $X = \sum_{i=1}^{n} X_i$ und $\mu = E(X) = \sum_{i=1}^{n} p_i$.

Definition 28 (Chernoff)

Seien $X_1, \ldots, X_n$ unabhängige, Bernoulli-verteilte Zufallsvariablen mit $X_i \sim Bern(p_i)$. Dann gelten die folgenden Ungleichungen für $X = \sum_{i=1}^{n} X_i$ und $\mu = E(X) = \sum_{i=1}^{n} p_i$.

- $P(X \geq (1+\delta)\mu) \leq \left(\frac{e^{\delta}}{(1+\delta)^{1+\delta}}\right)^{\mu}$ für alle $\delta > 0$;
- $P(X \leq (1-\delta)\mu) \leq \left(\frac{e^{-\delta}}{(1-\delta)^{1-\delta}}\right)^{\mu}$ für alle $0 < \delta < 1$

Definition 28 (Chernoff)

Seien $X_1, \ldots, X_n$ unabhängige, Bernoulli-verteilte Zufallsvariablen mit $X_i \sim Bern(p_i)$. Dann gelten die folgenden Ungleichungen für $X = \sum_{i=1}^{n} X_i$ und $\mu = E(X) = \sum_{i=1}^{n} p_i$.

- $P(X \geq (1+\delta)\mu) \leq \left(\frac{e^{\delta}}{(1+\delta)^{1+\delta}}\right)^{\mu}$ für alle $\delta > 0$;
- $P(X \leq (1-\delta)\mu) \leq \left(\frac{e^{-\delta}}{(1-\delta)^{1-\delta}}\right)^{\mu}$ für alle $0 < \delta < 1$;
- $P(X \geq (1+\delta)\mu) \leq e^{-\mu\delta^2/3}$ für alle $0 < \delta \leq 1$;
- $P(X \leq (1-\delta)\mu) \leq e^{-\mu\delta^2/2}$ für alle $0 < \delta \leq 1$;
- $P(|X-\mu| \geq \delta\mu) \leq 2e^{-\mu\delta^2/3}$ für alle $0 < \delta \leq 1$;
- $P(X \geq (1+\delta)\mu) \leq \left(\frac{e}{1+\delta}\right)^{(1+\delta)\mu}$; and
- $P(X \geq t) \leq 2^{-t}$ für alle $t \geq 2e\mu$.

Plan I

Kontinuierliche Zufallsvariablen
- Messbarkeitstheorie
- Kontinuierliche Wahrscheinlichkeitsräume
- Gleichverteilung
- Normalverteilung
- γ-Quantil
- Exponentialverteilung
- Multivariate Verteilungen
- Weitere Verteilungen

Kontinuierliche Zufallsvariablen

Definition 29

Eine kontinuierliche Zufallsvariable X ist eine Funktion

$$X : S \to \mathbb{R}$$

wobei $X(S)$ überabzählbar ist.

Kontinuierliche Zufallsvariablen

Definition 29

Eine kontinuierliche Zufallsvariable X ist eine Funktion

$$X : S \to \mathbb{R}$$

wobei $X(S)$ überabzählbar ist.

Die Verteilung von X ist definiert durch die kontinuierliche Dichtefunktion $f_X : \mathbb{R} \to \mathbb{R}_0^+$ mit der Eigenschaft

$$\int_{-\infty}^{+\infty} f_X(x)\ dx = 1.$$

Messbarkeitstheorie

Definition 30

- Eine Borel'sche Menge für $\mathbb{R}$ ist eine Teilmenge $A \subseteq \mathbb{R}$, die als durch abzählbare Vereinigungen und Schnitte von Intervallen (offen, halboffen, oder geschlossen) auf $\mathbb{R}$ dargestellt werden kann.

Messbarkeitstheorie

Definition 30

- Eine Borel'sche Menge für $\mathbb{R}$ ist eine Teilmenge $A \subseteq \mathbb{R}$, die als durch abzählbare Vereinigungen und Schnitte von Intervallen (offen, halboffen, oder geschlossen) auf $\mathbb{R}$ dargestellt werden kann.
- Eine Funktion $f : \mathbb{R} \to \mathbb{R}$ ist (Borel-)messbar, falls das Urbild jeder Borel'schen Menge ebenfalls eine Borel'sche Menge ist.

Messbarkeitstheorie

Definition 30

- Eine Borel'sche Menge für $\mathbb{R}$ ist eine Teilmenge $A \subseteq \mathbb{R}$, die als durch abzählbare Vereinigungen und Schnitte von Intervallen (offen, halboffen, oder geschlossen) auf $\mathbb{R}$ dargestellt werden kann.
- Eine Funktion $f : \mathbb{R} \to \mathbb{R}$ ist (Borel-)messbar, falls das Urbild jeder Borel'schen Menge ebenfalls eine Borel'sche Menge ist.
- Für eine messbar Funktion f schreiben wir das Lebesgue-Integral als $\int f \; d\lambda$.

Messbarkeitstheorie

Definition 30

- Eine Borel'sche Menge für $\mathbb{R}$ ist eine Teilmenge $A \subseteq \mathbb{R}$, die als durch abzählbare Vereinigungen und Schnitte von Intervallen (offen, halboffen, oder geschlossen) auf $\mathbb{R}$ dargestellt werden kann.
- Eine Funktion $f : \mathbb{R} \to \mathbb{R}$ ist (Borel-)messbar, falls das Urbild jeder Borel'schen Menge ebenfalls eine Borel'sche Menge ist.
- Für eine messbar Funktion f schreiben wir das Lebesgue-Integral als $\int f \; d\lambda$.

Example 31 (Beispiele messbarer Funktionen)

- die charakteristische Funktion 1_A der Menge A,
- stetige Funktionen, und
- Summen und Produkte messbarer Funktionen.

Wahrscheinlichkeitsräume über Borel'schen Mengen

Die Menge von Borel'schen Mengen $\mathcal{A}$ ist eine σ-Algebra über $\mathbb{R}$.

Wahrscheinlichkeitsräume über Borel'schen Mengen

Die Menge von Borel'schen Mengen $\mathcal{A}$ ist eine σ-Algebra über $\mathbb{R}$.

Eine Borel-messbare Funktion f mit den Eigenschaften einer kontinuierlichen Dichtefunktion definiert den Wahrscheinlichkeitsraum $(\mathbb{R}, \mathcal{A}, P)$

Wahrscheinlichkeitsräume über Borel'schen Mengen

Die Menge von Borel'schen Mengen $\mathcal{A}$ ist eine σ-Algebra über $\mathbb{R}$.

Eine Borel-messbare Funktion f mit den Eigenschaften einer kontinuierlichen Dichtefunktion definiert den Wahrscheinlichkeitsraum $(\mathbb{R}, \mathcal{A}, P)$ mit

$$P : A \mapsto \int f \cdot 1_A \, d\lambda.$$

Wahrscheinlichkeitsräume über Borel'schen Mengen

Die Menge von Borel'schen Mengen $\mathcal{A}$ ist eine σ-Algebra über $\mathbb{R}$.

Eine Borel-messbare Funktion f mit den Eigenschaften einer kontinuierlichen Dichtefunktion definiert den Wahrscheinlichkeitsraum $(\mathbb{R}, \mathcal{A}, P)$ mit

$$P : A \mapsto \int f \cdot 1_A \, d\lambda.$$

Insbesondere erfüllt P die Kolmogorov Axiome.

Kontinuierliche Wahrscheinlichkeitsräume

Definition 32

Ein Ereignis ist eine Menge $A = \bigcup_k I_k \subseteq \mathbb{R}$, die durch eine Vereinigung abzählbar vieler paarweise disjunkter Intervalle repräsentiert werden kann. Die Wahrscheinlichkeit von A ist gegeben als

$$P(A) = \int_A f_X(x)\ dx = \sum_k \int_{I_k} f_X(x)\ dx.$$

Kontinuierliche Wahrscheinlichkeitsräume

Definition 32

Ein Ereignis ist eine Menge $A = \bigcup_k I_k \subseteq \mathbb{R}$, die durch eine Vereinigung abzählbar vieler paarweise disjunkter Intervalle repräsentiert werden kann. Die Wahrscheinlichkeit von A ist gegeben als

$$P(A) = \int_A f_X(x)\ dx = \sum_k \int_{I_k} f_X(x)\ dx.$$

Die Wahrscheinlichkeit des Ereignisses $A = \{x\}, x \in \mathbb{R}$ ist immer 0.

Verteilungsfunktion

Die Verteilungsfunktion einer kontinuierlichen Zufallsvariable X ist gegeben als

$$F_X(x) = P(X \leq x)$$

Verteilungsfunktion

Die Verteilungsfunktion einer kontinuierlichen Zufallsvariable X ist gegeben als

$$F_X(x) = P(X \leq x) = P(X < x)$$

Verteilungsfunktion

Die Verteilungsfunktion einer kontinuierlichen Zufallsvariable X ist gegeben als

$$\begin{aligned} F_X(x) &= P(X \leq x) = P(X < x) \\ &= \int_{-\infty}^{x} f_X(t)\ dt. \end{aligned}$$

Verteilungsfunktion

Die Verteilungsfunktion einer kontinuierlichen Zufallsvariable X ist gegeben als

$$\begin{aligned} F_X(x) &= P(X \leq x) = P(X < x) \\ &= \int_{-\infty}^{x} f_X(t)\ dt. \end{aligned}$$

Die Dichtefunktion von X kann durch die Verteilungsfunktion von X erhalten werden indem ihre Ableitung bezüglich x gefunden wird:

$$f_X(x) = \frac{dF_X}{dx}.$$

Intervalle

Nach dem Hauptsatz der Differential- und Integralrechnung, ist die Wahrscheinlichkeit von $X \in [a, b]$ gegeben als

$$P(a \leq X \leq b) = F_X(b) - F_X(a) = \int_a^b f_X(x)\ dx.$$

Erwartungswerte

Der Erwartungswert einer kontinuierlichen Zufallsvariable X ist gegeben als

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x)\ dx.$$

Erwartungswerte

Der Erwartungswert einer kontinuierlichen Zufallsvariable X ist gegeben als

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x)\ dx.$$

LOTUS gilt auch im kontinuierlichen Fall:

$$E(g(X)) = \int_{-\infty}^{+\infty} g(x) \cdot f_X(x)\ dx.$$

Gleichverteilung

Definition 33 ($X \sim Unif(a, b)$)

Eine kontinuierliche Zufallsvariable X ist gleichverteilt mit Parametern a und b falls X den Ausgang eines Experimentes modelliert, wo alle Ergebnisse, die in dem Intervall $[a, b]$ liegen, gleichwahrscheinlich sind.

Gleichverteilung

Definition 33 ($X \sim Unif(a, b)$)

Eine kontinuierliche Zufallsvariable X ist gleichverteilt mit Parametern a und b falls X den Ausgang eines Experimentes modelliert, wo alle Ergebnisse, die in dem Intervall $[a, b]$ liegen, gleichwahrscheinlich sind.

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{für } x \in [a, b] \\ 0 & \text{sonst} \end{cases}.$$

Gleichverteilung

Definition 33 ($X \sim Unif(a, b)$)

Eine kontinuierliche Zufallsvariable X ist gleichverteilt mit Parametern a und b falls X den Ausgang eines Experimentes modelliert, wo alle Ergebnisse, die in dem Intervall $[a, b]$ liegen, gleichwahrscheinlich sind.

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{für } x \in [a, b] \\ 0 & \text{sonst} \end{cases} . \qquad F_X(x) = \begin{cases} 0 & \text{für } x < a \\ \frac{x-a}{b-a} & \text{für } x \in [a, b] \\ 1 & \text{für } x > b \end{cases} .$$

Gleichverteilung

Definition 33 ($X \sim Unif(a, b)$)

Eine kontinuierliche Zufallsvariable X ist gleichverteilt mit Parametern a und b falls X den Ausgang eines Experimentes modelliert, wo alle Ergebnisse, die in dem Intervall $[a, b]$ liegen, gleichwahrscheinlich sind.

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{für } x \in [a, b] \\ 0 & \text{sonst} \end{cases}. \qquad F_X(x) = \begin{cases} 0 & \text{für } x < a \\ \frac{x-a}{b-a} & \text{für } x \in [a, b] \\ 1 & \text{für } x > b \end{cases}.$$

Übersicht

- $E(X) = \frac{a+b}{2}$

Gleichverteilung

Definition 33 ($X \sim Unif(a, b)$)

Eine kontinuierliche Zufallsvariable X ist gleichverteilt mit Parametern a und b falls X den Ausgang eines Experimentes modelliert, wo alle Ergebnisse, die in dem Intervall $[a, b]$ liegen, gleichwahrscheinlich sind.

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{für } x \in [a, b] \\ 0 & \text{sonst} \end{cases}. \qquad F_X(x) = \begin{cases} 0 & \text{für } x < a \\ \frac{x-a}{b-a} & \text{für } x \in [a, b] \\ 1 & \text{für } x > b \end{cases}.$$

Übersicht

- $E(X) = \frac{a+b}{2}$
- $Var(X) = \frac{(a-b)^2}{12}$

Universalität der Gleichverteilung

Sei $X \sim F$. Dann gilt $F(X) \sim Unif(0,1)$.

Universalität der Gleichverteilung

Sei $X \sim F$. Dann gilt $F(X) \sim Unif(0,1)$.

Realisierungen einer Zufallsvariablen mit Verteilung F und inverser Verteilungsfunktion F^{-1} können mittels Realisierungen einer gleichverteilten Zufallsvariablen Y simuliert werden: $F^{-1}(Y) \sim F$.

Normalverteilung

Definition 34 ($X \sim \mathcal{N}(\mu, \sigma^2)$)

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) =: \varphi(x; \mu, \sigma).$$

$$F_X(x) =: \Phi(x; \mu, \sigma).$$

Normalverteilung

Definition 34 ($X \sim \mathcal{N}(\mu, \sigma^2)$)

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) =: \varphi(x; \mu, \sigma).$$

$$F_X(x) =: \Phi(x; \mu, \sigma).$$

Übersicht

- $E(X) = \mu$

Normalverteilung

Definition 34 ($X \sim \mathcal{N}(\mu, \sigma^2)$)

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) =: \varphi(x; \mu, \sigma).$$

$$F_X(x) =: \Phi(x; \mu, \sigma).$$

Übersicht

- $E(X) = \mu$
- $Var(X) = \sigma^2$

Normalverteilung

Definition 34 ($X \sim \mathcal{N}(\mu, \sigma^2)$)

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) =: \varphi(x; \mu, \sigma).$$

$$F_X(x) =: \Phi(x; \mu, \sigma).$$

Übersicht

- $E(X) = \mu$
- $Var(X) = \sigma^2$
- $M_Z(s) = exp(\mu s + \frac{(\sigma s)^2}{2})$

$\mathcal{N}(0,1)$ heißt Standardnormalverteilung.

$\mathcal{N}(0,1)$ heißt Standardnormalverteilung.

Lineare Transformation

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$. Dann ist für alle $a \in \mathbb{R} \setminus \{0\}$ und $b \in \mathbb{R}$ die Zufallsvariable

$$Y = aX + b$$

normalverteilt mit Erwartungswert $a\mu + b$ und Varianz $a^2\sigma^2$.

$\mathcal{N}(0,1)$ heißt Standardnormalverteilung.

Lineare Transformation

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$. Dann ist für alle $a \in \mathbb{R} \setminus \{0\}$ und $b \in \mathbb{R}$ die Zufallsvariable

$$Y = aX + b$$

normalverteilt mit Erwartungswert $a\mu + b$ und Varianz $a^2\sigma^2$.

Normierung

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$ und $Y = \frac{X-\mu}{\sigma}$. Dann gilt $Y \sim \mathcal{N}(0,1)$.

$\mathcal{N}(0,1)$ heißt Standardnormalverteilung.

Lineare Transformation

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$. Dann ist für alle $a \in \mathbb{R} \setminus \{0\}$ und $b \in \mathbb{R}$ die Zufallsvariable

$$Y = aX + b$$

normalverteilt mit Erwartungswert $a\mu + b$ und Varianz $a^2\sigma^2$.

Normierung

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$ und $Y = \frac{X-\mu}{\sigma}$. Dann gilt $Y \sim \mathcal{N}(0,1)$.
Die Zufallsvariable Y heißt auch normiert.

Additivität

Seien $X_1, \ldots, X_n$ unabhängig und normalverteilt mit Parametern μ_i, σ_i^2. Dann ist die Zufallsvariable

$$Z = a_1 X_1 + \cdots + a_n X_n$$

normalverteilt mit Erwartungswert $a_1\mu_1 + \cdots a_n\mu_n$ und Varianz $a_1^2\sigma_1^2 + \cdots + a_n^2\sigma_n^2$.

Additivität

Seien $X_1, \ldots, X_n$ unabhängig und normalverteilt mit Parametern μ_i, σ_i^2. Dann ist die Zufallsvariable

$$Z = a_1 X_1 + \cdots + a_n X_n$$

normalverteilt mit Erwartungswert $a_1\mu_1 + \cdots a_n\mu_n$ und Varianz $a_1^2\sigma_1^2 + \cdots + a_n^2\sigma_n^2$.

Normal-Approximation der Binomialverteilung

Sei $X \sim Bin(n, p)$ mit Verteilungsfunktion $F_n(t)$. Dann kann

$$F_n(t) \approx \Phi\left(\frac{t - np}{\sqrt{p(1-p)n}}\right)$$

als Approximation verwendet werden falls $np \geq 5$ und $n(1-p) \geq 5$.

γ-Quantil

Definition 35

Sei X eine kontinuierliche Zufallsvariable mit Verteilung F_x. Eine Zahl x_γ mit

$$F_X(x_\gamma) = \gamma$$

heißt γ-Quantil von X bzw. der Verteilung F_X.

γ-Quantil

Definition 35

Sei X eine kontinuierliche Zufallsvariable mit Verteilung F_x. Eine Zahl x_γ mit

$$F_X(x_\gamma) = \gamma$$

heißt γ-Quantil von X bzw. der Verteilung F_X.

Definition 36

Für die Standardnormalverteilung bezeichnet z_γ das γ-Quantil.

Exponentialverteilung

Definition 37 ($X \sim Exp(\lambda)$)

Eine kontinuierliche Zufallsvariable X ist exponentialverteilt mit Parameter λ falls X die Zeit zwischen Ereignissen eines Poisson-Prozesses modelliert.

Exponentialverteilung

Definition 37 ($X \sim Exp(\lambda)$)

Eine kontinuierliche Zufallsvariable X ist exponentialverteilt mit Parameter λ falls X die Zeit zwischen Ereignissen eines Poisson-Prozesses modelliert.

$$f_X(x) = \lambda e^{-\lambda x}.$$

Exponentialverteilung

Definition 37 ($X \sim Exp(\lambda)$)

Eine kontinuierliche Zufallsvariable X ist exponentialverteilt mit Parameter λ falls X die Zeit zwischen Ereignissen eines Poisson-Prozesses modelliert.

$$f_X(x) = \lambda e^{-\lambda x}. \qquad F_X(x) = 1 - e^{-\lambda x}.$$

Exponentialverteilung

Definition 37 ($X \sim Exp(\lambda)$)

Eine kontinuierliche Zufallsvariable X ist exponentialverteilt mit Parameter λ falls X die Zeit zwischen Ereignissen eines Poisson-Prozesses modelliert.

$$f_X(x) = \lambda e^{-\lambda x}. \qquad F_X(x) = 1 - e^{-\lambda x}.$$

Übersicht

- $E(X) = \frac{1}{\lambda}$

Exponentialverteilung

Definition 37 ($X \sim Exp(\lambda)$)

Eine kontinuierliche Zufallsvariable X ist exponentialverteilt mit Parameter λ falls X die Zeit zwischen Ereignissen eines Poisson-Prozesses modelliert.

$$f_X(x) = \lambda e^{-\lambda x}. \qquad F_X(x) = 1 - e^{-\lambda x}.$$

Übersicht

- $E(X) = \frac{1}{\lambda}$
- $Var(X) = \frac{1}{\lambda^2}$

Exponentialverteilung

Definition 37 ($X \sim Exp(\lambda)$)

Eine kontinuierliche Zufallsvariable X ist exponentialverteilt mit Parameter λ falls X die Zeit zwischen Ereignissen eines Poisson-Prozesses modelliert.

$$f_X(x) = \lambda e^{-\lambda x}. \qquad F_X(x) = 1 - e^{-\lambda x}.$$

Übersicht

- $E(X) = \frac{1}{\lambda}$
- $Var(X) = \frac{1}{\lambda^2}$
- $M_X(s) = \frac{\lambda}{\lambda - s}, s < \lambda$

Skalierung

Sei $X \sim Exp(\lambda)$. Falls $a > 0$, dann ist $Y = aX$ exponentialverteilt mit dem Parameter λ/a.

Skalierung

Sei $X \sim Exp(\lambda)$. Falls $a > 0$, dann ist $Y = aX$ exponentialverteilt mit dem Parameter λ/a.

Gedächtnislosigkeit

Die Exponentialverteilung ist die einzige gedächtnislose kontinuierliche Verteilung. Daher ist jede kontinuierliche Zufallsvariable X für die

$$P(X > y + x | X > x) = P(X > y)$$

für all $x, y > 0$ gilt, exponentialverteilt.

Warten auf mehrere Ereignisse

Seien $X_1, \ldots, X_n$ unabhängige, exponentialverteilte Zufallsvariablen mit Parametern $\lambda_1, \ldots, \lambda_n$. Dann ist $X = \min\{X_1, \ldots, X_n\}$ exponentialverteilt mit Parameter $\lambda_1 + \cdots + \lambda_n$.

Warten auf mehrere Ereignisse

Seien $X_1, \ldots, X_n$ unabhängige, exponentialverteilte Zufallsvariablen mit Parametern $\lambda_1, \ldots, \lambda_n$. Dann ist $X = \min\{X_1, \ldots, X_n\}$ exponentialverteilt mit Parameter $\lambda_1 + \cdots + \lambda_n$.

Exponential-Approximation der geometrischen Verteilung

Sei $X_n \sim Geom(\lambda/n)$. Die Verteilung der skalierten geometrisch verteilten Zufallsvariablen $Y_n = \frac{1}{n} X_n$ konvergiert mit $n \to \infty$ zu einer Exponentialverteilung mit Parameter λ.

Poisson-Prozess

Seien $T_1, T_2, \ldots \sim Exp(\lambda)$ unabhängige und gleichverteilte Zufallsvariablen, die die Zeit zwischen dem $(i-1)$-ten und dem i-ten Ereignis modellieren.

Poisson-Prozess

Seien $T_1, T_2, \ldots \sim Exp(\lambda)$ unabhängige und gleichverteilte Zufallsvariablen, die die Zeit zwischen dem $(i-1)$-ten und dem i-ten Ereignis modellieren.
Für $t > 0$ definieren wir

$$X(t) = \max\{n \in \mathbb{N} \mid T_1 + \cdots + T_n \leq t\},$$

das die Anzahl der Ereignisse repräsentiert, die bis zum Zeitpunkt t augetreten sind.

Poisson-Prozess

Seien $T_1, T_2, \ldots \sim Exp(\lambda)$ unabhängige und gleichverteilte Zufallsvariablen, die die Zeit zwischen dem $(i-1)$-ten und dem i-ten Ereignis modellieren.
Für $t > 0$ definieren wir

$$X(t) = \max\{n \in \mathbb{N} \mid T_1 + \cdots + T_n \leq t\},$$

das die Anzahl der Ereignisse repräsentiert, die bis zum Zeitpunkt t augetreten sind.
Dann ist $X(t)$ Poisson-verteilt mit Parameter $t\lambda$.

Multivariate Verteilungen

Randverteilungen finden

Gegeben eine multivariate Verteilung $f_{X,Y}$ kann die Randverteilung f_X wie folgt gefunden werden:

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\ dy.$$

Multivariate Verteilungen

Randverteilungen finden

Gegeben eine multivariate Verteilung $f_{X,Y}$ kann die Randverteilung f_X wie folgt gefunden werden:

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\ dy.$$

Wahrscheinlichkeiten berechnen

Gegeben ein Ereignis $A \in \mathbb{R}^2$. Die Wahrscheinlichkeit von A ist die Fläche unter der Dichtefunktion von X:

$$P(A) = \iint_A f_{X,Y}(x, y)\ dx\ dy.$$

Dichtefunktionen finden

Gegeben eine Verteilungsfunktion $F_{X,Y}$ kann die Dichtefunktion $f_{X,Y}$ wie folgt gefunden werden:

$$f_{X,Y}(x,y) = \frac{\partial^2 F_{X,Y}}{\partial x \partial y}(x,y).$$

Dichtefunktionen finden

Gegeben eine Verteilungsfunktion $F_{X,Y}$ kann die Dichtefunktion $f_{X,Y}$ wie folgt gefunden werden:

$$f_{X,Y}(x,y) = \frac{\partial^2 F_{X,Y}}{\partial x \partial y}(x,y).$$

Verteilungsfunktionen finden

Gegeben eine Dichtefunktion $f_{X,Y}$ kann die Verteilungsfunktion $F_{X,Y}$ wie folgt gefunden werden:

$$F_{X,Y}(x,y) = \int_{-\infty}^{y} \int_{-\infty}^{x} f_{X,Y}(u,v)\ du\ dv.$$

Weitere Verteilungen

Definition 38 ($X \sim \mathit{Lognormal}(\mu, \sigma^2)$)

Eine kontinuierliche Zufallsvariable X ist logarithmisch normalverteilt mit Parametern μ und σ^2 falls $Y = \mathit{ln}(X) \sim \mathcal{N}(\mu, \sigma^2)$.

Weitere Verteilungen

Definition 38 ($X \sim Lognormal(\mu, \sigma^2)$)

Eine kontinuierliche Zufallsvariable X ist logarithmisch normalverteilt mit Parametern μ und σ^2 falls $Y = ln(X) \sim \mathcal{N}(\mu, \sigma^2)$.

$$f_X(x) = \frac{1}{x\sigma\sqrt{2\pi}} \cdot exp\left(-\frac{(ln(x) - \mu)^2}{2\sigma^2}\right)$$

für $x > 0$.

Plan I

Induktive Statistik

- Schätzer
- Maximum-Likelihood-Schätzer
- Gesetz der großen Zahlen
- Zentraler Grenzwertsatz
- Konfidenzintervalle
- Hypothesentests
- Statistische Tests

Induktive Statistik

Induktive Statistik versucht mittels gemessener Größen auf zugrundeliegende Gesetzmäßigkeiten zu schließen.

Induktive Statistik

Induktive Statistik versucht mittels gemessener Größen auf zugrundeliegende Gesetzmäßigkeiten zu schließen.
Um Daten zu generieren, werden n unabhängige Kopien eines identischen Experimentes durchgeführt, das durch die Zufallsvariable X modelliert wird. Eine Messung, die aus einem dieser Experimente resultiert, heißt Stichprobe.

Induktive Statistik

Induktive Statistik versucht mittels gemessener Größen auf zugrundeliegende Gesetzmäßigkeiten zu schließen.
Um Daten zu generieren, werden n unabhängige Kopien eines identischen Experimentes durchgeführt, das durch die Zufallsvariable X modelliert wird. Eine Messung, die aus einem dieser Experimente resultiert, heißt Stichprobe.
Jede Stichprobe wird durch eine separate Zufallsvariable X_i repräsentiert, die als Stichprobenvariable bezeichnet wird.

Schätzer

Definition 39

Ein Schätzer für Parameter θ ist eine Zufallsvariable, die mehrere Stichprobenvariablen kombiniert und verwendet wird, um θ abzuschätzen.

Schätzer

Definition 39

Ein Schätzer für Parameter θ ist eine Zufallsvariable, die mehrere Stichprobenvariablen kombiniert und verwendet wird, um θ abzuschätzen.

Der Bias eines Schätzers U ist gegeben als $E(U - \theta)$.

Schätzer

Definition 39

Ein Schätzer für Parameter θ ist eine Zufallsvariable, die mehrere Stichprobenvariablen kombiniert und verwendet wird, um θ abzuschätzen.

Der Bias eines Schätzers U ist gegeben als $E(U - \theta)$.

Ein Schätzer U ist erwartungstreu bezüglich dem Parameter θ falls $E(U) = \theta$
(d.h. der Bias des Schätzers ist Null).

Definition 40

Das Stichprobenmittel $\bar{X}$ ist ein erwartungstreuer Schätzer für $E(X)$.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i.$$

Definition 40

Das Stichprobenmittel $\bar{X}$ ist ein erwartungstreuer Schätzer für $E(X)$.

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Definition 41

Die Stichprobenvarianz S^2 ist ein erwartungstreuer Schätzer für $Var(X)$.

$$S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2}.$$

Definition 42

Der mean squared error ist ein Gütemaß für einen Schätzer U.

$$MSE(U) = E((U - \theta)^2).$$

Definition 42

Der mean squared error ist ein Gütemaß für einen Schätzer U.

$$MSE(U) = E((U - \theta)^2).$$

Falls U erwartungstreu ist, so gilt $MSE(U) = Var(U)$.

Definition 42

Der mean squared error ist ein Gütemaß für einen Schätzer U.

$$MSE(U) = E((U - \theta)^2).$$

Falls U erwartungstreu ist, so gilt $MSE(U) = Var(U)$.

Ein Schätzer A ist effizienter als ein anderer Schätzer B falls $MSE(A) < MSE(B)$.

Definition 42

Der mean squared error ist ein Gütemaß für einen Schätzer U.

$$MSE(U) = E((U - \theta)^2).$$

Falls U erwartungstreu ist, so gilt $MSE(U) = Var(U)$.

Ein Schätzer A ist effizienter als ein anderer Schätzer B falls $MSE(A) < MSE(B)$.

Ein Schätzer U ist konsistent im quadratischen Mittel falls $MSE(U) \xrightarrow{n \to \infty} 0$.

Maximum-Likelihood-Schätzer

Die Maximum-Likelihood-Konstruktion ist ein Verfahren zur Konstruktion eines Schätzers für Parameter von einer gegbenen Verteilung. Wir finden also den Parameter, für den die gemessenen Werte am wahrscheinlichsten sind. In anderen Worten, wir finden die Funktion, die am wahrscheinlichsten die Stichproben erklärt.

Maximum-Likelihood-Schätzer

Die Maximum-Likelihood-Konstruktion ist ein Verfahren zur Konstruktion eines Schätzers für Parameter von einer gegbenen Verteilung. Wir finden also den Parameter, für den die gemessenen Werte am wahrscheinlichsten sind. In anderen Worten, wir finden die Funktion, die am wahrscheinlichsten die Stichproben erklärt.

Gegeben Stichprobenvariablen $\overrightarrow{X} = (X_1, \ldots, X_n)$ und Stichproben $\overrightarrow{x} = (x_1, \ldots, x_n)$, finde einen Maximum-Likelihood-Schätzer für X mit Parameter θ.

1. konstruiere $L(\overrightarrow{x}; \theta) = f_{\overrightarrow{X}}(\overrightarrow{x}; \theta) = \prod_{i=1}^{n} f_{X_i}(x_i; \theta)$, das die Wahrscheinlichkeit modelliert, dass die Stichproben $\overrightarrow{x}$ durch θ beschrieben werden
2. finde θ, das L maximiert, oder äquivalent $\ln L(\overrightarrow{x}; \theta) = \sum_{i=1}^{n} \ln f_{X_i}(x_i; \theta)$
3. der Wert für θ, der L maximiert, ist ein Maximum-Likelihood-Schätzer für θ

Gesetz der großen Zahlen

Das Gesetz der großen Zahlen besagt, dass das Stichprobenmittel aus unabhängigen und gleichverteilten Stichprobenvariablen $\bar{X}$ mit Wahrscheinlichkeit 1 gegen den Erwartungswert $E(X)$ konvergiert während sich die Stichprobengröße n Unendlich annähert.

Gesetz der großen Zahlen

Das Gesetz der großen Zahlen besagt, dass das Stichprobenmittel aus unabhängigen und gleichverteilten Stichprobenvariablen $\bar{X}$ mit Wahrscheinlichkeit 1 gegen den Erwartungswert $E(X)$ konvergiert während sich die Stichprobengröße n Unendlich annähert.

$$P(|\bar{X} - E(X)| \geq \delta) \leq \epsilon$$

für $\delta, \epsilon > 0$ und $n \geq \frac{Var(X)}{\epsilon\delta^2}$.

Zentraler Grenzwertsatz

Der zentrale Grenzwertsatz besagt, dass die normierte Summe von Stichprobenvariablen sich einer Standardnormalverteilung annähert während sich die Stichprobengröße n Unendlich annähert selbst wenn die zugrundeliegende Verteilung nicht die Normalverteilung ist.

Zentraler Grenzwertsatz

Der zentrale Grenzwertsatz besagt, dass die normierte Summe von Stichprobenvariablen sich einer Standardnormalverteilung annähert während sich die Stichprobengröße n Unendlich annähert selbst wenn die zugrundeliegende Verteilung nicht die Normalverteilung ist.

$$\frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{n\to\infty} \mathcal{N}(0,1) \text{ in der Verteilung}$$

für X_i unabhängig und identisch verteilt.

Zentraler Grenzwertsatz

Der zentrale Grenzwertsatz besagt, dass die normierte Summe von Stichprobenvariablen sich einer Standardnormalverteilung annähert während sich die Stichprobengröße n Unendlich annähert selbst wenn die zugrundeliegende Verteilung nicht die Normalverteilung ist.

$$\frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{n\to\infty} \mathcal{N}(0,1) \text{ in der Verteilung}$$

für X_i unabhängig und identisch verteilt.

Equivalent:

$$\sqrt{n}\left(\frac{\bar{X} - \mu}{\sigma}\right) \xrightarrow{n\to\infty} \mathcal{N}(0,1) \text{ in der Verteilung.}$$

Grenzwertsatz nach de Moivre

Der Grenzwertsatz nach de Moivre ist ein Spezialfall des zentralen Grenzwertsatzes und sagt aus, dass die Normalverteilung als Approximation für die Binomialverteilung verwendet werden kann.

Grenzwertsatz nach de Moivre

Der Grenzwertsatz nach de Moivre ist ein Spezialfall des zentralen Grenzwertsatzes und sagt aus, dass die Normalverteilung als Approximation für die Binomialverteilung verwendet werden kann.

Seien $X_1, \ldots, X_n \sim Bern(p)$ unabhängig und gleichverteilt sowie $H_n = X_1 + \cdots + X_n$. Dann gilt

$$H_n^* = \frac{H_n - np}{\sqrt{np(1-p)}} \xrightarrow{n \to \infty} \mathcal{N}(0,1) \text{ in der Verteilung.}$$

Konfidenzintervalle

Oft werden zwei Schätzer verwendet, um die abzuschätzende Größe aus beiden Richtungen abzuschätzen.

Konfidenzintervalle

Oft werden zwei Schätzer verwendet, um die abzuschätzende Größe aus beiden Richtungen abzuschätzen.
Die beiden Schätzer U_1 und U_2 werden so gewählt, dass

$$P(U_1 \leq \theta \leq U_2) \geq 1 - \alpha.$$

Konfidenzintervalle

Oft werden zwei Schätzer verwendet, um die abzuschätzende Größe aus beiden Richtungen abzuschätzen.
Die beiden Schätzer U_1 und U_2 werden so gewählt, dass

$$P(U_1 \leq \theta \leq U_2) \geq 1 - \alpha.$$

Die Wahrscheinlichkeit $1 - \alpha$ heißt Konfidenzniveau.

Konfidenzintervalle

Oft werden zwei Schätzer verwendet, um die abzuschätzende Größe aus beiden Richtungen abzuschätzen.
Die beiden Schätzer U_1 und U_2 werden so gewählt, dass

$$P(U_1 \leq \theta \leq U_2) \geq 1 - \alpha.$$

Die Wahrscheinlichkeit $1 - \alpha$ heißt Konfidenzniveau.

Berechnen wir für konkrete Stichproben die Schätzer U_1 und U_2 und erwarten $\theta \in [U_1, U_2]$, dann liegt die Fehlerwahrscheinlichkeit bei α. $[U_1, U_2]$ ist ein Konfidenzintervall.

Konfidenzintervalle

Oft werden zwei Schätzer verwendet, um die abzuschätzende Größe aus beiden Richtungen abzuschätzen.
Die beiden Schätzer U_1 und U_2 werden so gewählt, dass

$$P(U_1 \leq \theta \leq U_2) \geq 1 - \alpha.$$

Die Wahrscheinlichkeit $1 - \alpha$ heißt Konfidenzniveau.

Berechnen wir für konkrete Stichproben die Schätzer U_1 und U_2 und erwarten $\theta \in [U_1, U_2]$, dann liegt die Fehlerwahrscheinlichkeit bei α. $[U_1, U_2]$ ist ein Konfidenzintervall.

Oft wird ein einziger Schätzer U verwendet, um das symmetrische Konfidenzintervall $[U - \delta, U + \delta]$ zu definieren.

Hypothesentests

Gegeben Stichprobenvariablen $\overrightarrow{X} = (X_1, \ldots, X_n)$ und Stichprobenwerte $\overrightarrow{x} = (x_1, \ldots, x_n)$ entscheide, ob eine Hypothese akzeptiert oder abgelehnt werden soll.

Hypothesentests

Gegeben Stichprobenvariablen $\overrightarrow{X} = (X_1, \ldots, X_n)$ und Stichprobenwerte $\overrightarrow{x} = (x_1, \ldots, x_n)$ entscheide, ob eine Hypothese akzeptiert oder abgelehnt werden soll.

$K = \{\overrightarrow{x} \in \mathbb{R}^n \mid \overrightarrow{x}$ resultiert in Ablehnung der Hypothese$\}$ heißt kritischer Bereich (oder Ablehnungsbereich) eines Tests.

Hypothesentests

Gegeben Stichprobenvariablen $\overrightarrow{X} = (X_1, \ldots, X_n)$ und Stichprobenwerte $\overrightarrow{x} = (x_1, \ldots, x_n)$ entscheide, ob eine Hypothese akzeptiert oder abgelehnt werden soll.

$K = \{\overrightarrow{x} \in \mathbb{R}^n \mid \overrightarrow{x}$ resultiert in Ablehnung der Hypothese$\}$ heißt kritischer Bereich (oder Ablehnungsbereich) eines Tests.

K wird basierend auf den konkreten Werten der Testvariablen T gewählt, die sich aus den Stichprobenvariablen zusammensetzt.

Hypothesentests

Gegeben Stichprobenvariablen $\overrightarrow{X} = (X_1, \ldots, X_n)$ und Stichprobenwerte $\overrightarrow{x} = (x_1, \ldots, x_n)$ entscheide, ob eine Hypothese akzeptiert oder abgelehnt werden soll.

$K = \{\overrightarrow{x} \in \mathbb{R}^n \mid \overrightarrow{x}$ resultiert in Ablehnung der Hypothese$\}$ heißt kritischer Bereich (oder Ablehnungsbereich) eines Tests.

K wird basierend auf den konkreten Werten der Testvariablen T gewählt, die sich aus den Stichprobenvariablen zusammensetzt.

Ein Test heißt einseitig falls K ein halboffenes Intervall in $T(S)$ ist und beidseitig falls K ein geschlossenes Intervall in $T(S)$ ist.

H_0 ist die Hypothese auf die getestet wird, auch als Nullhypothese bezeichnet.
H_1 ist die Alternative. H_1 ist trivial falls es die einfache Negation von H_0 ist.

H_0 ist die Hypothese auf die getestet wird, auch als Nullhypothese bezeichnet.
H_1 ist die Alternative. H_1 ist trivial falls es die einfache Negation von H_0 ist.

Fehler

- Fehler 1. Art oder α-Fehler oder Signifikanzniveau
  H_0 gilt, aber $\overrightarrow{x} \in K$

$$\alpha = \sup_{p \in H_0} P_p(T \in K).$$

H_0 ist die Hypothese auf die getestet wird, auch als Nullhypothese bezeichnet.
H_1 ist die Alternative. H_1 ist trivial falls es die einfache Negation von H_0 ist.

Fehler

- Fehler 1. Art oder α-Fehler oder Signifikanzniveau
  H_0 gilt, aber $\overrightarrow{x} \in K$

$$\alpha = \sup_{p \in H_0} P_p(T \in K).$$

- Fehler 2. Art oder β-Fehler
  H_1 gilt, aber $\overrightarrow{x} \notin K$

$$\beta = \sup_{p \in H_1} P_p(T \notin K).$$

Die Gütefunktion g beschreibt die Wahrscheinlichkeit, dass ein Test die Nullhypothese ablehnt.

$$g(p) = P_p(T \in K).$$

Statistische Tests

Eigenschaften

Statistische Tests können anhand einiger Merkmale unterschieden werden:

- **Anzahl beteiligter Zufallsgrößen**

Statistische Tests

Eigenschaften

Statistische Tests können anhand einiger Merkmale unterschieden werden:

- **Anzahl beteiligter Zufallsgrößen**
  Vergleich zweier Zufallsvariablen mit potenziell unterschiedlichen Verteilungen (Zwei-Stichproben-Test), oder Untersuchung einer Zufallsvariable (Ein-Stichproben-Test)?

Statistische Tests

Eigenschaften

Statistische Tests können anhand einiger Merkmale unterschieden werden:

- **Anzahl beteiligter Zufallsgrößen**
  Vergleich zweier Zufallsvariablen mit potenziell unterschiedlichen Verteilungen (Zwei-Stichproben-Test), oder Untersuchung einer Zufallsvariable (Ein-Stichproben-Test)?
  - Unabhängigkeit beteiligter Zufallsvariablen
    Bei dem Vergleich mehrerer Zufallsvariablen wird unterschieden, ob unabhängige Messungen (Unabhängigkeit) oder verbundene Messungen (Abhängigkeit) vorgenommen werden.

Statistische Tests

Eigenschaften

Statistische Tests können anhand einiger Merkmale unterschieden werden:

- **Anzahl beteiligter Zufallsgrößen**
  Vergleich zweier Zufallsvariablen mit potenziell unterschiedlichen Verteilungen (Zwei-Stichproben-Test), oder Untersuchung einer Zufallsvariable (Ein-Stichproben-Test)?
  - Unabhängigkeit beteiligter Zufallsvariablen
    Bei dem Vergleich mehrerer Zufallsvariablen wird unterschieden, ob unabhängige Messungen (Unabhängigkeit) oder verbundene Messungen (Abhängigkeit) vorgenommen werden.
  - Betrachtung des Zusammenhangs mehrerer Zufallsvariablen
    Wird der funktionale Zusammenhang mehrerer Zufallsvariablen untersucht spricht man von einer Regressionsanalyse. Werden die Zufallsvariablen auf Unabhängigkeit untersucht spricht man von einer Zusammenhangsanalyse.

- **Formulierung der Nullhypothese**

- **Formulierung der Nullhypothese**
  Über welche Lageparameter macht der Test eine Aussage (z.B Erwartungswert oder Varianz), oder wird auf eine vorgegebene Verteilung getestet?

- **Formulierung der Nullhypothese**
  Über welche Lageparameter macht der Test eine Aussage (z.B Erwartungswert oder Varianz), oder wird auf eine vorgegebene Verteilung getestet?
- **Annahmen über die Zufallsgrößen**

- **Formulierung der Nullhypothese**
  Über welche Lageparameter macht der Test eine Aussage (z.B Erwartungswert oder Varianz), oder wird auf eine vorgegebene Verteilung getestet?
- **Annahmen über die Zufallsgrößen**
  Welche Annahmen macht der Test über die Zufallsvariablen wie zum Beispiel die Art der Verteilung, Erwartungswert, oder Varianz?

Wichtige statistische Testverfahren

Wichtige statistische Testverfahren

- Approximativer Binomialtest

Wichtige statistische Testverfahren

- Approximativer Binomialtest
- Gaußtest

Wichtige statistische Testverfahren

- Approximativer Binomialtest
- Gaußtest
- t-Test

Wichtige statistische Testverfahren

- Approximativer Binomialtest
- Gaußtest
- t-Test
- Zwei-Stichproben-t-Test

Wichtige statistische Testverfahren

- Approximativer Binomialtest
- Gaußtest
- t-Test
- Zwei-Stichproben-t-Test
- χ^2-Anpassungstest

Plan I

Markovketten
- Stochastische Prozesse
- Markov-Bedingung
- Repräsentationen
- Wahrscheinlichkeiten
- Übergangszeiten
- Stationäre Verteilung
- Exkurs: Diagonalisierung
- Konvergenz
- Eigenschaften

Stochastische Prozesse

Definition 43

Ein stochastischer Prozess ist eine Folge von Zufallsvariablen $(X_t)_{t \in T}$, die das Verhalten eines Systems zu verschiedenen Zeitpunkten t angeben.

Stochastische Prozesse

Definition 43

Ein stochastischer Prozess ist eine Folge von Zufallsvariablen $(X_t)_{t \in T}$, die das Verhalten eines Systems zu verschiedenen Zeitpunkten t angeben.

Gilt $T = \mathbb{N}_0$, so spricht man von einem stochastischen Prozess mit diskreter Zeit.

Stochastische Prozesse

Definition 43

Ein stochastischer Prozess ist eine Folge von Zufallsvariablen $(X_t)_{t \in T}$, die das Verhalten eines Systems zu verschiedenen Zeitpunkten t angeben.

Gilt $T = \mathbb{N}_0$, so spricht man von einem stochastischen Prozess mit diskreter Zeit. Gilt hingegen $T = \mathbb{R}_0^+$, so spricht man von einem stochastischen Prozess mit kontinuierlicher Zeit.
Falls X_t diskret ist, spricht man auch von unterschiedlichen Zuständen die ein System zum Zeitpunkt t annimmt.

Markov-Bedingung

Definition 44

Ein stochastischer Prozess erfüllt die Markov-Bedingung, falls die Wahrscheinlichkeitsverteilung der Zustände zum Zeitpunkt $t + 1$ nur von der Wahrscheinlichkeitsverteilung der Zustände zum Zeitpunkt t abhängt, nicht aber von Zuständen zum Zeitpunkt $< t$.

Markov-Bedingung

Definition 44

Ein stochastischer Prozess erfüllt die Markov-Bedingung, falls die Wahrscheinlichkeitsverteilung der Zustände zum Zeitpunkt $t+1$ nur von der Wahrscheinlichkeitsverteilung der Zustände zum Zeitpunkt t abhängt, nicht aber von Zuständen zum Zeitpunkt $< t$.

Diese Bedingung kann wie folgt formalisiert werden:

$$P(X_{t+1} = j | X_t = i_t, \ldots, X_0 = i_0) = P(X_{t+1} = j | X_t = i_t)$$

Markov-Bedingung

Definition 44

Ein stochastischer Prozess erfüllt die Markov-Bedingung, falls die Wahrscheinlichkeitsverteilung der Zustände zum Zeitpunkt $t+1$ nur von der Wahrscheinlichkeitsverteilung der Zustände zum Zeitpunkt t abhängt, nicht aber von Zuständen zum Zeitpunkt $< t$.

Diese Bedingung kann wie folgt formalisiert werden:

$$P(X_{t+1} = j | X_t = i_t, \ldots, X_0 = i_0) = P(X_{t+1} = j | X_t = i_t) =: p^t_{i_t j}.$$

Definition 45

Eine (endliche) Markov-Kette (mit diskreter Zeit) über Zustandsmenge $S = \{0, \ldots, n-1\}$ besteht aus einer unendlichen Folge von Zufallsvariablen $(X_t)_{t \in \mathbb{N}_0}$ mit Wertebereich S

Definition 45

Eine (endliche) Markov-Kette (mit diskreter Zeit) über Zustandsmenge $S = \{0, \ldots, n-1\}$ besteht aus einer unendlichen Folge von Zufallsvariablen $(X_t)_{t \in \mathbb{N}_0}$ mit Wertebereich S und Startverteilung q_0 mit $q_0^T \in \mathbb{R}^n$.

Definition 45

Eine (endliche) Markov-Kette (mit diskreter Zeit) über Zustandsmenge $S = \{0, \ldots, n-1\}$ besteht aus einer unendlichen Folge von Zufallsvariablen $(X_t)_{t \in \mathbb{N}_0}$ mit Wertebereich S und Startverteilung q_0 mit $q_0^T \in \mathbb{R}^n$. q_0 muss als Zeilenvektor eine valide diskrete Dichtefunktion auf der Zustandsmenge S beschreiben.

Definition 45

Eine (endliche) Markov-Kette (mit diskreter Zeit) über Zustandsmenge $S = \{0, \ldots, n-1\}$ besteht aus einer unendlichen Folge von Zufallsvariablen $(X_t)_{t \in \mathbb{N}_0}$ mit Wertebereich S und Startverteilung q_0 mit $q_0^T \in \mathbb{R}^n$. q_0 muss als Zeilenvektor eine valide diskrete Dichtefunktion auf der Zustandsmenge S beschreiben. Weiterhin muss die Markov-Bedingung erfüllt sein.

Repräsentationen

Definition 46

Sind die Übergangswahrscheinlichkeiten $p_{ij} = P(X_{t+1} = j | X_t = i)$ konstant mit der Zeit t, so spricht man von einer (zeit-)homogenen Markov-Kette.

Repräsentationen

Definition 46

Sind die Übergangswahrscheinlichkeiten $p_{ij} = P(X_{t+1} = j | X_t = i)$ konstant mit der Zeit t, so spricht man von einer (zeit-)homogenen Markov-Kette.

In diesem Fall definiert man die Übergangsmatrix durch $P = (p_{ij})_{0 \leq i,j < n}$.

Repräsentationen

Definition 46

Sind die Übergangswahrscheinlichkeiten $p_{ij} = P(X_{t+1} = j | X_t = i)$ konstant mit der Zeit t, so spricht man von einer (zeit-)homogenen Markov-Kette.

In diesem Fall definiert man die Übergangsmatrix durch $P = (p_{ij})_{0 \leq i,j < n}$.

Das Übergangsdiagramm ist ein Graph bestehend aus den Zuständen S wobei die gewichteten Kanten durch P repräsentiert werden.

Repräsentationen

Definition 46

Sind die Übergangswahrscheinlichkeiten $p_{ij} = P(X_{t+1} = j | X_t = i)$ konstant mit der Zeit t, so spricht man von einer (zeit-)homogenen Markov-Kette.

In diesem Fall definiert man die Übergangsmatrix durch $P = (p_{ij})_{0 \leq i,j < n}$.

Das Übergangsdiagramm ist ein Graph bestehend aus den Zuständen S wobei die gewichteten Kanten durch P repräsentiert werden.

Einen konkreten Ablauf des Systems kann man sich auch als Random Walk auf dem Übergangsdiagramm vorstellen.

Wahrscheinlichkeiten

Die Verteilung einer Markov-Kette kann iterativ für immer größere Zeitpunkte t bestimmt werden:

$$q_{t+1} = q_t \cdot P$$

Wahrscheinlichkeiten

Die Verteilung einer Markov-Kette kann iterativ für immer größere Zeitpunkte t bestimmt werden:

$$q_{t+1} = q_t \cdot P$$
$$q_t = q_0 \cdot P^t$$

Wahrscheinlichkeiten

Die Verteilung einer Markov-Kette kann iterativ für immer größere Zeitpunkte t bestimmt werden:

$$\begin{aligned} q_{t+1} &= q_t \cdot P \\ q_t &= q_0 \cdot P^t \\ q_{t+k} &= q_t \cdot P^k. \end{aligned}$$

Wahrscheinlichkeiten

Die Verteilung einer Markov-Kette kann iterativ für immer größere Zeitpunkte t bestimmt werden:

$$\begin{aligned} q_{t+1} &= q_t \cdot P \\ q_t &= q_0 \cdot P^t \\ q_{t+k} &= q_t \cdot P^k. \end{aligned}$$

Definition 47

q_t wird auch als Zustandsvektor der Markov-Kette zum Zeitpunkt t bezeichnet.

Wahrscheinlichkeiten

Die Verteilung einer Markov-Kette kann iterativ für immer größere Zeitpunkte t bestimmt werden:

$$\begin{aligned} q_{t+1} &= q_t \cdot P \\ q_t &= q_0 \cdot P^t \\ q_{t+k} &= q_t \cdot P^k. \end{aligned}$$

Definition 47

q_t wird auch als Zustandsvektor der Markov-Kette zum Zeitpunkt t bezeichnet.

Die Einträge von P^k geben an, mit welcher Wahrscheinlichkeit ein Übergang von Zustand i in Zustand j in genau k Schritten erfolgt:

$$p_{ij}^{(k)} = P(X_{t+k} = j | X_t = i) = (P^k)_{ij}.$$

Übergangszeiten

Definition 48

Die Übergangszeit von Zustand i in Zustand j wird durch die folgende Zufallsvariable modelliert:

$$T_{ij} = \min\{n \geq 1 \mid X_n = j, \text{ wenn } X_0 = i\}.$$

Übergangszeiten

Definition 48

Die Übergangszeit von Zustand i in Zustand j wird durch die folgende Zufallsvariable modelliert:

$$T_{ij} = \min\{n \geq 1 \mid X_n = j, \text{ wenn } X_0 = i\}.$$

Die erwartete Übergangszeit ist gegeben durch

$$h_{ij} = E(T_{ij})$$

Übergangszeiten

Definition 48

Die Übergangszeit von Zustand i in Zustand j wird durch die folgende Zufallsvariable modelliert:

$$T_{ij} = \min\{n \geq 1 \mid X_n = j, \text{ wenn } X_0 = i\}.$$

Die erwartete Übergangszeit ist gegeben durch

$$\begin{aligned} h_{ij} &= E(T_{ij}) \\ &= 1 + \sum_{k \neq j} p_{ik} h_{kj}. \end{aligned}$$

Die Wahrscheinlichkeit vom Zustand i in beliebig vielen Schritten in den Zustand j zu gelangen, heißt Ankunftswahrscheinlichkeit f_{ij}:

$$f_{ij} = P(T_{ij} < \infty)$$

Die Wahrscheinlichkeit vom Zustand i in beliebig vielen Schritten in den Zustand j zu gelangen, heißt Ankunftswahrscheinlichkeit f_{ij}:

$$\begin{aligned} f_{ij} &= P(T_{ij} < \infty) \\ &= p_{ij} + \sum_{k \neq j} p_{ik} f_{kj}. \end{aligned}$$

Die Wahrscheinlichkeit vom Zustand i in beliebig vielen Schritten in den Zustand j zu gelangen, heißt Ankunftswahrscheinlichkeit f_{ij}:

$$\begin{aligned} f_{ij} &= P(T_{ij} < \infty) \\ &= p_{ij} + \sum_{k \neq j} p_{ik} f_{kj}. \end{aligned}$$

Definition 49

Die Zufallsvariable $T_i = T_{ii}$ gibt die Rückkehrzeit von Zustand i zu Zustand i an.

Die Wahrscheinlichkeit vom Zustand i in beliebig vielen Schritten in den Zustand j zu gelangen, heißt Ankunftswahrscheinlichkeit f_{ij}:

$$\begin{aligned} f_{ij} &= P(T_{ij} < \infty) \\ &= p_{ij} + \sum_{k \neq j} p_{ik} f_{kj}. \end{aligned}$$

Definition 49

Die Zufallsvariable $T_i = T_{ii}$ gibt die Rückkehrzeit von Zustand i zu Zustand i an.

Die erwartete Rückkehrzeit $h_i = h_{ii}$ und die Rückkehrwahrscheinlichkeit $f_i = f_{ii}$ sind analog zu der erwarteten Übergangszeit und der Ankunftswahrscheinlichkeit definiert.

Stationäre Verteilung

Definition 50

Ein Zustandsvektor π mit $\pi = \pi \cdot P$ heißt stationäre Verteilung einer Markov-Kette.

Stationäre Verteilung

Definition 50

Ein Zustandsvektor π mit $\pi = \pi \cdot P$ heißt stationäre Verteilung einer Markov-Kette.

Eine Markovkette konvergiert nicht notwendigerweise in eine ihrer stationären Verteilungen. Konvergenz hängt von den Eigenschaften der Markovkette und der Startverteilung ab.

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Damit gilt für eine quadratische Matrix A mit Eigenvektoren $x_1, \ldots, x_n$ und zugehörigen Eigenwerten $\lambda_1, \ldots, \lambda_n$

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Damit gilt für eine quadratische Matrix A mit Eigenvektoren $x_1, \ldots, x_n$ und zugehörigen Eigenwerten $\lambda_1, \ldots, \lambda_n$, dass

$$A \cdot \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix}$$

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Damit gilt für eine quadratische Matrix A mit Eigenvektoren $x_1, \ldots, x_n$ und zugehörigen Eigenwerten $\lambda_1, \ldots, \lambda_n$, dass

$$A \cdot \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} = \begin{bmatrix} \lambda_1 x_1 & \cdots & \lambda_n x_n \end{bmatrix}$$

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Damit gilt für eine quadratische Matrix A mit Eigenvektoren $x_1, \ldots, x_n$ und zugehörigen Eigenwerten $\lambda_1, \ldots, \lambda_n$, dass

$$\begin{aligned} A \cdot \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} &= \begin{bmatrix} \lambda_1 x_1 & \cdots & \lambda_n x_n \end{bmatrix} \\ &= \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} \cdot \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_n \end{bmatrix}. \end{aligned}$$

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Damit gilt für eine quadratische Matrix A mit Eigenvektoren $x_1, \ldots, x_n$ und zugehörigen Eigenwerten $\lambda_1, \ldots, \lambda_n$, dass

$$\begin{aligned} A \cdot \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} &= \begin{bmatrix} \lambda_1 x_1 & \cdots & \lambda_n x_n \end{bmatrix} \\ &= \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} \cdot \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_n \end{bmatrix}. \end{aligned}$$

Sei V die Matrix bestehend aus den Eigenvektoren von A als Spaltenvektoren und sei Λ die Diagonalmatrix bestehend aus den Eigenwerten von A.

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Damit gilt für eine quadratische Matrix A mit Eigenvektoren $x_1, \ldots, x_n$ und zugehörigen Eigenwerten $\lambda_1, \ldots, \lambda_n$, dass

$$\begin{aligned} A \cdot \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} &= \begin{bmatrix} \lambda_1 x_1 & \cdots & \lambda_n x_n \end{bmatrix} \\ &= \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} \cdot \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_n \end{bmatrix}. \end{aligned}$$

Sei V die Matrix bestehend aus den Eigenvektoren von A als Spaltenvektoren und sei Λ die Diagonalmatrix bestehend aus den Eigenwerten von A.

Dann heißt $V^{-1} \cdot A \cdot V = \Lambda$ Diagonalisierung von A.

Exkurs: Diagonalisierung

Für Eigenvektoren x_i und zugehörige Eigenwerte λ_i einer Matrix A gilt $A \cdot x_i = \lambda_i \cdot x_i$.

Damit gilt für eine quadratische Matrix A mit Eigenvektoren $x_1, \ldots, x_n$ und zugehörigen Eigenwerten $\lambda_1, \ldots, \lambda_n$, dass

$$\begin{aligned} A \cdot \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} &= \begin{bmatrix} \lambda_1 x_1 & \cdots & \lambda_n x_n \end{bmatrix} \\ &= \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} \cdot \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_n \end{bmatrix}. \end{aligned}$$

Sei V die Matrix bestehend aus den Eigenvektoren von A als Spaltenvektoren und sei Λ die Diagonalmatrix bestehend aus den Eigenwerten von A.

Dann heißt $V^{-1} \cdot A \cdot V = \Lambda$ Diagonalisierung von A.
Andererseits gilt auch, dass $A = V \cdot \Lambda \cdot V^{-1}$.

Konvergenz

Aus der Diagonalisierung der Übergangsmatrix folgt direkt, dass

$$P^t = V \cdot \Lambda^t \cdot V^{-1}.$$

Konvergenz

Aus der Diagonalisierung der Übergangsmatrix folgt direkt, dass

$$P^t = V \cdot \Lambda^t \cdot V^{-1}.$$

Damit kann das Verhalten der Markovkette für $t \to \infty$ beschreiben werden:

$$\lim_{t \to \infty} q_t$$

Konvergenz

Aus der Diagonalisierung der Übergangsmatrix folgt direkt, dass

$$P^t = V \cdot \Lambda^t \cdot V^{-1}.$$

Damit kann das Verhalten der Markovkette für $t \to \infty$ beschreiben werden:

$$\lim_{t \to \infty} q_t = \lim_{t \to \infty} q_0 \cdot P^t.$$

Konvergenz

Aus der Diagonalisierung der Übergangsmatrix folgt direkt, dass

$$P^t = V \cdot \Lambda^t \cdot V^{-1}.$$

Damit kann das Verhalten der Markovkette für $t \to \infty$ beschreiben werden:

$$\lim_{t\to\infty} q_t = \lim_{t\to\infty} q_0 \cdot P^t.$$

$$\lim_{t\to\infty} P(X_t = j \mid X_0 = i)$$

Konvergenz

Aus der Diagonalisierung der Übergangsmatrix folgt direkt, dass

$$P^t = V \cdot \Lambda^t \cdot V^{-1}.$$

Damit kann das Verhalten der Markovkette für $t \to \infty$ beschreiben werden:

$$\lim_{t\to\infty} q_t = \lim_{t\to\infty} q_0 \cdot P^t.$$
$$\lim_{t\to\infty} P(X_t = j \mid X_0 = i) = \lim_{t\to\infty} P^t(i,j).$$

Eigenschaften

Weißt eine Markovkette bestimmte Eigenschaften auf, können Rückschlüsse auf ihre stationäre Verteilung gezogen werden.

Eigenschaften

Weißt eine Markovkette bestimmte Eigenschaften auf, können Rückschlüsse auf ihre stationäre Verteilung gezogen werden.

Definition 51

Ein Zustand i heißt absorbierend, falls $p_{ii} = 1$, d.h. aus ihm führen keine Übergänge heraus.

Eigenschaften

Weißt eine Markovkette bestimmte Eigenschaften auf, können Rückschlüsse auf ihre stationäre Verteilung gezogen werden.

Definition 51

Ein Zustand i heißt absorbierend, falls $p_{ii} = 1$, d.h. aus ihm führen keine Übergänge heraus.

Ein Zustand i heißt rekurrent, falls $f_i = 1$, d.h. mit Wahrscheinlichkeit 1 kehrt die Markovkette in den Zustand i zurück.

Eigenschaften

Weißt eine Markovkette bestimmte Eigenschaften auf, können Rückschlüsse auf ihre stationäre Verteilung gezogen werden.

Definition 51

Ein Zustand i heißt absorbierend, falls $p_{ii} = 1$, d.h. aus ihm führen keine Übergänge heraus.

Ein Zustand i heißt rekurrent, falls $f_i = 1$, d.h. mit Wahrscheinlichkeit 1 kehrt die Markovkette in den Zustand i zurück.
Falls hingegen $f_i < 1$ gilt, heißt der Zustand i transient.

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt.

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt. Das heißt formal:

$$\forall i, j \in S.\ \exists n \in \mathbb{N}.\ p_{ij}^{(n)} > 0.$$

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt. Das heißt formal:

$$\forall i, j \in S.\ \exists n \in \mathbb{N}.\ p_{ij}^{(n)} > 0.$$

Eine endliche Markov-Kette ist genau dann irreduzibel wenn ihr Übergangsdiagramm stark zusammenhängend ist.

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt. Das heißt formal:

$$\forall i, j \in S.\ \exists n \in \mathbb{N}.\ p_{ij}^{(n)} > 0.$$

Eine endliche Markov-Kette ist genau dann irreduzibel wenn ihr Übergangsdiagramm stark zusammenhängend ist.

Wenn eine endliche Markov-Kette irreduzibel ist gilt zudem:

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt. Das heißt formal:

$$\forall i, j \in S.\ \exists n \in \mathbb{N}.\ p_{ij}^{(n)} > 0.$$

Eine endliche Markov-Kette ist genau dann irreduzibel wenn ihr Übergangsdiagramm stark zusammenhängend ist.

Wenn eine endliche Markov-Kette irreduzibel ist gilt zudem:

- $f_{ij} = 1, \forall i, j \in S$

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt. Das heißt formal:

$$\forall i, j \in S.\ \exists n \in \mathbb{N}.\ p_{ij}^{(n)} > 0.$$

Eine endliche Markov-Kette ist genau dann irreduzibel wenn ihr Übergangsdiagramm stark zusammenhängend ist.

Wenn eine endliche Markov-Kette irreduzibel ist gilt zudem:

- $f_{ij} = 1, \forall i, j \in S$;
- h_{ij} existiert, $\forall i, j \in S$

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt. Das heißt formal:

$$\forall i, j \in S.\ \exists n \in \mathbb{N}.\ p_{ij}^{(n)} > 0.$$

Eine endliche Markov-Kette ist genau dann irreduzibel wenn ihr Übergangsdiagramm stark zusammenhängend ist.

Wenn eine endliche Markov-Kette irreduzibel ist gilt zudem:

- $f_{ij} = 1, \forall i, j \in S$;
- h_{ij} existiert, $\forall i, j \in S$; und
- es existiert eine eindeutige stationäre Verteilung π mit $\pi(j) = \frac{1}{h_j}, \forall j \in S$.

Definition 52

Eine Markov-Kette heißt irreduzibel wenn man von jedem Zustand jeden anderen Zustand mit positiver Wahrscheinlichkeit erreicht, wenn man nur genügend Schritte ausführt. Das heißt formal:

$$\forall i, j \in S.\ \exists n \in \mathbb{N}.\ p_{ij}^{(n)} > 0.$$

Eine endliche Markov-Kette ist genau dann irreduzibel wenn ihr Übergangsdiagramm stark zusammenhängend ist.

Wenn eine endliche Markov-Kette irreduzibel ist gilt zudem:

- $f_{ij} = 1, \forall i, j \in S$;
- h_{ij} existiert, $\forall i, j \in S$; und
- es existiert eine eindeutige stationäre Verteilung π mit $\pi(j) = \frac{1}{h_j}, \forall j \in S$.

Die Markov-Kette muss nicht zwingend in eine stationäre Verteilung konvergieren (Periodizität!).

Nun wollen wir die Periodizität von Zuständen betrachten.

Nun wollen wir die Periodizität von Zuständen betrachten.

Definition 53

Für einen Zustand i definieren wir

$$T(i) = \{n \geq 1 \mid P^n(i,i) > 0\}.$$

Nun wollen wir die Periodizität von Zuständen betrachten.

Definition 53

Für einen Zustand i definieren wir

$$T(i) = \{n \geq 1 \mid P^n(i,i) > 0\}.$$

Dann ist die Periode des Zustandes i definiert als $d_i = gcd(T(i))$.

Nun wollen wir die Periodizität von Zuständen betrachten.

Definition 53

Für einen Zustand i definieren wir

$$T(i) = \{n \geq 1 \mid P^n(i,i) > 0\}.$$

Dann ist die Periode des Zustandes i definiert als $d_i = gcd(T(i))$.

Falls eine Markovkette irreduzibel ist, ist die Periode aller Zustände gleich. Diese Periode wird dann als Periode der Markovkette bezeichnet.

Definition 54

Ein Zustand i heißt aperiodisch, falls $d_i = 1$

Definition 54

Ein Zustand i heißt aperiodisch, falls $d_i = 1$, oder equivalent, falls $\exists n_0 \in \mathbb{N}.\ \forall n \geq n_0.\ p_{ii}^{(n)} > 0$.

Definition 54

Ein Zustand i heißt aperiodisch, falls $d_i = 1$, oder equivalent, falls $\exists n_0 \in \mathbb{N}.\ \forall n \geq n_0.\ p_{ii}^{(n)} > 0$.

Somit ist ein Zustand i aperiodisch genau dann wenn es im Übergansdiagramm für alle $n \in \mathbb{N}$ ab einem $n_0 \in \mathbb{N}$ einen geschlossenen Weg der Länge n von i nach i gibt.

Definition 54

Ein Zustand i heißt aperiodisch, falls $d_i = 1$, oder equivalent, falls $\exists n_0 \in \mathbb{N}.\ \forall n \geq n_0.\ p_{ii}^{(n)} > 0$.

Somit ist ein Zustand i aperiodisch genau dann wenn es im Übergansdiagramm für alle $n \in \mathbb{N}$ ab einem $n_0 \in \mathbb{N}$ einen geschlossenen Weg der Länge n von i nach i gibt.

Das heißt Zustand i ist sicherlich dann aperiodisch wenn er im Übergangsdiagramm

- eine Schleife besitzt ($p_{ii} > 0$)

Definition 54

Ein Zustand i heißt aperiodisch, falls $d_i = 1$, oder equivalent, falls $\exists n_0 \in \mathbb{N}.\ \forall n \geq n_0.\ p_{ii}^{(n)} > 0$.

Somit ist ein Zustand i aperiodisch genau dann wenn es im Übergansdiagramm für alle $n \in \mathbb{N}$ ab einem $n_0 \in \mathbb{N}$ einen geschlossenen Weg der Länge n von i nach i gibt.

Das heißt Zustand i ist sicherlich dann aperiodisch wenn er im Übergangsdiagramm

- eine Schleife besitzt ($p_{ii} > 0$) oder
- auf mindestens zwei geschlossenen Pfaden P_1 und P_2 liegt, deren Längen teilerfremd sind.

Definition 54

Ein Zustand i heißt aperiodisch, falls $d_i = 1$, oder equivalent, falls $\exists n_0 \in \mathbb{N}.\ \forall n \geq n_0.\ p_{ii}^{(n)} > 0$.

Somit ist ein Zustand i aperiodisch genau dann wenn es im Übergansdiagramm für alle $n \in \mathbb{N}$ ab einem $n_0 \in \mathbb{N}$ einen geschlossenen Weg der Länge n von i nach i gibt.

Das heißt Zustand i ist sicherlich dann aperiodisch wenn er im Übergangsdiagramm

- eine Schleife besitzt ($p_{ii} > 0$) oder
- auf mindestens zwei geschlossenen Pfaden P_1 und P_2 liegt, deren Längen teilerfremd sind.

Eine Markov-Kette heißt aperiodisch falls alle ihre Zustände aperiodisch sind.

Definition 55

Eine irreduzible und aperiodische Markov-Kette heißt ergodisch.

Definition 55

Eine irreduzible und aperiodische Markov-Kette heißt ergodisch.

Für jede endliche ergodische Markov-Kette gilt unabhängig der Startverteilung q_0, dass

$$\lim_{t \to \infty} q_t = \pi$$

wobei π die eindeutige stationäre Verteilung bezeichnet.

Definition 56

Eine quadratische Matrix A heißt stochastisch, falls sich alle Zeilen zu Eins aufsummieren.

Definition 56

Eine quadratische Matrix A heißt stochastisch, falls sich alle Zeilen zu Eins aufsummieren.
Jede Übergangsmatrix P ist stochastisch.

Definition 56

Eine quadratische Matrix A heißt stochastisch, falls sich alle Zeilen zu Eins aufsummieren.
Jede Übergangsmatrix P ist stochastisch.

A heißt zusätzlich doppeltstochastisch, falls sich auch alle Spalten zu Eins aufsummieren.

Definition 56

Eine quadratische Matrix A heißt stochastisch, falls sich alle Zeilen zu Eins aufsummieren.
Jede Übergangsmatrix P ist stochastisch.

A heißt zusätzlich doppeltstochastisch, falls sich auch alle Spalten zu Eins aufsummieren.

Für jede endliche ergodische Markov-Kette mit doppeltstochastischer Übergangsmatrix gilt, dass die stationäre Verteilung jedem Zustand die gleiche Wahrscheinlichkeit zuweist:

$$\pi \equiv \frac{1}{|S|}.$$